

دانشگاه صنعتی خواجه نصیرالدین طوسی

دانشکده مهندسی کامپیوتر

گزارش جامع نهایی پروژه داده‌کاوی پیشرفته

کشف و تفسیر پروفایل‌های توسعه‌دهندگان در پیمایش ۲۰۲۴ Stack Overflow

مرصاد احمدی — علی حسن زاده

۴۰۳۰۴۴۶۴ — ۴۰۳۰۱۲۷۴

استاد: دکتر پیشگو

تیر ۱۴۰۵ / July ۲۰۲۶

۲	فهرست مطالب
۴	چکیده
۵	۱. مقدمه و تعریف مسئله
۵	۱.۱. انگیزه پژوهش
۵	۱.۲. سؤال و اهداف پژوهش
۵	۱.۳. دامنه و ادعا
۵	۲. داده، منشأ و ملاحظات اخلاقی
۵	۲.۱. منبع داده
۶	۲.۲. متغیرهای تحلیلی
۶	۲.۳. اخلاق، سوگیری و محدودیت نمونه
۶	۳. آماده‌سازی داده و مهندسی ویژگی
۶	۳.۱. کنترل کیفیت و پاک‌سازی
۸	۳.۲. ساخت نمایش ویژگی
۹	۳.۳. مقیاس‌بندی
۱۰	۴. کاهش بعد، فاصله و گرایش خوشه‌ای
۱۰	۴.۱. PCA، SVD و UMAP
۱۲	۴.۲. انتخاب معیار فاصله
۱۲	۴.۳. VAT و Hopkins
۱۳	۵. سبد الگوریتم‌ها و طراحی آزمایش
۱۴	۶. انتخاب k و ارزیابی مقایسه‌ای
۱۴	۶.۱. شواهد انتخاب k
۱۵	۶.۲. مقایسه خانواده‌ها
۱۷	۶.۳. متغیرهای کمکی، پایداری و توافق
۱۸	۷. مسیر پیشرفته اصلی: Consensus Clustering
۱۸	۷.۱. ساخت ماتریس co-association
۱۹	۷.۲. تعمیم به کل cohort
۲۰	۸. تفسیر خوشه‌ها و توضیح‌پذیری
۲۰	۸.۱. پروفایل‌های نهایی

۸.۲. فناوری‌های شاخص.....	۲۱
۸.۳. نمونه‌ها، قواعد و SHAP.....	۲۲
۹. تحلیل پایین‌دستی و ناهنجاری.....	۲۴
۹.۱. مدل جبران خدمت.....	۲۴
۹.۲. تشخیص ناهنجاری خوشه‌محور.....	۲۴
۱۰. انصاف، composition و حساسیت.....	۲۵
۱۰.۱. ممیزی composition.....	۲۵
۱۰.۲. حساسیت به پیش‌پردازش.....	۲۶
۱۱. مسیر پیشرفته دوم و امتیازهای افزوده.....	۲۷
۱۱.۱. NMF پربعد.....	۲۷
۱۱.۲. فاصله اطمینان و permutation.....	۲۸
۱۱.۳. پایداری split و UMAP سه‌بعدی.....	۲۸
۱۲. خط تولید، بازتولیدپذیری و داشبورد.....	۲۹
۱۲.۱. معماری pipeline.....	۲۹
۱۲.۲. پایش drift.....	۳۰
۱۲.۳. داشبورد تعاملی.....	۳۱
۱۲.۴. دستور بازتولید.....	۳۱
۱۳. بحث و محدودیت‌ها.....	۳۱
۱۴. نتیجه‌گیری.....	۳۱
منابع.....	۳۲
پیوست الف — شبکه پارامترها.....	۳۲
پیوست ب — جدول کامل راه‌حل‌های برتر فاز دوم.....	۳۳

این پروژه یک مطالعه کامل خوشه‌بندی بدون نظارت روی پیمایش توسعه‌دهندگان Stack Overflow در سال ۲۰۲۴ است. پرسش اصلی آن است که آیا از ترکیب پشته فناوری، تجربه حرفه‌ای و بستر کاری می‌توان پروفایل‌های طبیعی، پایدار و قابل تفسیر استخراج کرد و این پروفایل‌ها تا چه اندازه برای تحلیل‌های بعدی ارزش دارند. از ۶۵,۴۳۷ پاسخ خام و ۱۱۴ ستون، پس از کنترل schema، تحلیل گمشدگی و حذف ۵,۴۱۴ پاسخ فاقد هرگونه اطلاعات فناوری، cohort نهایی ۶۰,۰۲۳ نفری ساخته شد. نمایش کامل شامل ۳۲۸ ویژگی و نمایش فناوری شامل ۲۴۱ ویژگی است. RobustScaler انتخاب شد و PCA با ۵۰ مؤلفه، ۷۷.۷۶٪ واریانس را حفظ کرد.

در فاز دوم، ۷۸ پیکربندی از پنج خانواده partitioning، سلسله‌مراتبی، چگالی‌محور، مدل‌مبنا و Spectral با معیارهای داخلی، متغیرهای کمکی، پایداری bootstrap، seed، و توافق زوجی مقایسه شدند. شواهد تعداد خوشه هم‌جهت نبودند: silhouette و جمع رتبه‌ها K=۲ مقدار ۶، ۱-SE Gap مقدار ۷ و بهترین پایداری bootstrap مقدار ۳ را پیشنهاد کردند. در فاز سوم، consensus مبتنی بر co-association مقدار K=۲ را برگزید و دو پروفایل با اندازه‌های ۴۵,۹۶۹ و ۱۴,۰۵۴ ساخت. دقت انتساب روی holdout برابر ۹۶.۴٪ و fidelity درخت توضیحی ۹۸.۹٪ بود. تفاوت غالب دو خوشه پهنای پشته فناوری با میانه‌های ۱۴ و ۳۲ فناوری است. نتیجه باید یک طیف اکتشافی تلقی شود، نه دو نوع ذاتی از انسان‌ها یا مبنای تصمیم‌گیری فردی.

جمع‌بندی اصلی در داده ساختاری غیرتصادفی و قابل توضیح دیده شد، اما هم‌پوشانی خوشه‌ها، اختلاف معیارهای K، حساسیت به scaler و بهترنشدن مدل‌های جبران خدمت شرطی بر خوشه نشان می‌دهند که اعتبار نتیجه توصیفی و فرضیه‌ساز است، نه علی یا قطعی.

شاخص	نتیجه نهایی
پاسخ خام / cohort نهایی	۶۵,۴۳۷ / ۶۰,۰۲۳
نمایش اصلی	۳۲۸ ویژگی؛ PCA-۵۰
پیکربندی‌های فاز دوم	۷۸
روش و K نهایی	Consensus؛ K=۲
اندازه خوشه‌ها	۴۵,۹۶۹ / ۱۴,۰۵۴
دقت انتساب	۹۶.۴٪
امتیاز افزوده هدف	۱۵ امتیاز

۳.۰۱ Section ۱.۱. انگیزه پژوهش

پیمایش Stack Overflow تصویری پربعد از تجربه، نقش، محیط کار و فناوری‌های توسعه‌دهندگان فراهم می‌کند. گزارش‌های توصیفی معمولاً هر متغیر را جداگانه بررسی می‌کنند، در حالی که شخصیت فنی یک توسعه‌دهنده حاصل ترکیب هم‌زمان زبان‌ها، پایگاه‌های داده، پلتفرم‌ها، ابزارها، سابقه و زمینه شغلی است. خوشه‌بندی امکان می‌دهد الگوهای مشترک بدون تعریف برجسته از پیش تعیین‌شده کشف شوند؛ با این حال نتیجه فقط زمانی معتبر است که وجود ساختار، پایداری، حساسیت و قابلیت تفسیر آن جداگانه آزموده شوند.

۳.۰۲ Section ۱.۲. سؤال و اهداف پژوهش

سؤال مرکزی چه پروفایل‌های طبیعی توسعه‌دهندگان از الگوهای مشترک پشته فناوری، تجربه حرفه‌ای و بستر کاری در پیمایش Stack Overflow ۲۰۲۴ پدیدار می‌شوند، و این پروفایل‌ها چه ارتباطی با نقش، تحصیلات و پذیرش ابزارهای هوش مصنوعی دارند؟

اهداف عملیاتی پژوهش عبارت‌اند از:

- ساخت pipeline بازتولیدپذیر برای ورود، پاک‌سازی، مهندسی ویژگی، کاهش بعد و خوشه‌بندی.
- آزمون وجود گرایش خوشه‌ای پیش از انتخاب الگوریتم یا تعداد خوشه.
- مقایسه منصفانه چند خانواده الگوریتم و چند معیار انتخاب k روی نمونه‌ها و نمایش‌های ثابت.
- سنجش پایداری seed و bootstrap، توافق الگوریتم‌ها و حساسیت به پیش‌پردازش.
- تفسیر انسانی خوشه‌ها با پروفایل، فناوری‌های شاخص، exemplar، درخت تصمیم و SHAP.
- بررسی ارزش پایین‌دستی، ناهنجاری، composition و محدودیت‌های اخلاقی استفاده از نتیجه.

۳.۰۳ Section ۱.۳. دامنه و ادعا

این پژوهش اکتشافی است. DevType، EdLevel، AISelect و ConvertedCompYearly از فضای clustering کنار گذاشته شدند تا ارزیابی دوری ایجاد نشود؛ این متغیرها فقط برای تفسیر یا تحلیل پایین‌دستی استفاده می‌شوند. بنابراین NMI یا سایر معیارهای خارجی نسبت به آن‌ها معیار انطباق با یک برجسته مرجع نیست. همچنین نام خوشه‌ها توصیفی است و نباید برای رتبه‌بندی، استخدام یا ارزیابی افراد استفاده شود.

Article IV. ۲. داده، منشأ و ملاحظات اخلاقی

۴.۰۱ Section ۲.۱. منبع داده

منبع اصلی ۲۰۲۴ Stack Overflow Developer Survey است. فایل survey_results_public.csv پاسخ‌های عمومی و فایل survey_results_schema.csv متن پرسش‌ها و schema رسمی را نگه می‌دارد. ورودی اصلی با خواندن chunked ده‌هزارردیفی پردازش و هش SHA-۲۵۶ هر فایل ثبت شد. از Responseld فقط برای ردیابی ردیف در artifact‌ها استفاده شده و هیچ تلاش برای شناسایی هویت افراد انجام نشده است.

مقدار	مولفه داده
۶۵,۴۳۷	تعداد پاسخ خام
۱۱۴	تعداد ستون خام
۲۱	ستون‌های منتخب pipeline
۱۰,۰۰۰	اندازه chunk
۶۰,۰۲۳	cohort نهایی
۴۲	seed پایه

۴.۰۲ Section ۲.۲. متغیرهای تحلیلی

ورودی خوشه‌بندی شامل سه سنجه تجربه، اندازه سازمان، وضعیت اشتغال، دورکاری، کشور و هفت خانواده فناوری است: زبان برنامه‌نویسی، پایگاه داده، پلتفرم، چارچوب وب، فناوری embedded، ابزار و سایر فناوری‌ها. نقش، تحصیلات، پذیرش AI و جبران خدمت برای تفسیر نگه داشته شدند. این جداسازی مانع از آن می‌شود که خوشه‌ها مستقیماً نسخه‌ای از یک برچسب شناخته‌شده باشند.

۴.۰۳ Section ۲.۳. اخلاق، سوگیری و محدودیت نمونه

داده خوداظهاری و حاصل مشارکت داوطلبانه است؛ بنابراین نماینده کامل تمام توسعه‌دهندگان جهان نیست. گم‌شدگی متغیرها، تفاوت دسترسی منطقه‌ای به Stack Overflow و تفاوت در تفسیر پرسش‌ها می‌تواند ترکیب cohort را تغییر دهد. تحلیل composition برای کشور، تحصیلات، دورکاری و پذیرش AI انجام شد، اما نتیجه توصیفی آن نباید به ادعای برابری یا تبعیض علی تبدیل شود.

Article ۷. ۳. آماده‌سازی داده و مهندسی ویژگی


۵.۰۱ Section ۳.۱. کنترل کیفیت و پاک‌سازی

pipeline ابتدا schema ستون‌های موردنیاز را بررسی کرد. شناسه تکراری و شکست صریح آزمون توجه مشاهده نشد. تعداد ۵,۴۱۴ ردیف که در تمام حوزه‌های فناوری فاقد پاسخ بودند حذف شدند؛ در نتیجه ۶۰,۰۲۳ رکورد باقی ماند. تعداد ۱۳۸ کشور با فراوانی کمتر از ۲۰۰ در گروه Other ادغام شد تا ابعاد one-hot و ناپایداری دسته‌های کم‌نمونه کنترل شود.

عبارت‌های متنی تجربه مانند «کمتر از یک سال» و «بیش از ۵۰ سال» به مقادیر عددی ۰/۵ و ۵۱ تبدیل شدند. گم‌شدگی تجربه ابتدا با میانه کشور و سپس با میانه سراسری تکمیل شد و indicator گم‌شدگی نیز حفظ گردید. OrgSize به midpoint بازه نگاشت و log_{۱p} شد. ConvertedCompYearly فقط در تحلیل پایین‌دستی استفاده شد و در فضای clustering حضور ندارد.

ردیف متأثر	اقدام	مسئله	ستون
۳۵۷۷۹	country-median imputation with global median fallback; retain WorkExpNumericMissing	missing experience	WorkExpNumeric
۱۷۹۵۷	map ranges to midpoints, median-impute unknowns, then log _{۱p}	ordinal ranges and missing/unknown values	OrgSize
۱۳۸۲۷	country-median imputation with global median fallback; retain YearsCodeProNumericMissing	missing experience	YearsCodeProNumeric
۵۵۶۸	country-median imputation with global median fallback; retain YearsCodeNumericMissing	missing experience	YearsCodeNumeric
۵۴۱۴	exclude rows with all seven domains missing	no response in all seven technology domains	technology matrix
۵۳۰۱	group countries with fewer than ۲۰۰ respondents as Other	high cardinality / rare categories	Country
۲۳۸۸	strip text and map empty strings to missing	whitespace/type consistency	MiscTechHaveWorkedWith
.	strip text and map empty strings to missing	whitespace/type consistency	YearsCode
.	strip text and map empty strings to missing	whitespace/type consistency	MainBranch
.	strip text and map empty strings to missing	whitespace/type consistency	Employment
.	strip text and map empty strings to missing	whitespace/type consistency	RemoteWork

ردیف متأثر	اقدام	مسئله	ستون
.	strip text and map empty strings to missing	whitespace/type consistency	Check




شکل ۱ — الگوی گمشدگی ستون‌های منتخب پیش از پاک‌سازی

Section ۵.۰۲.۳. ساخت نمایش ویژگی

هفت ستون چندبرچسبی فناوری به ۲۴۰ شاخص دودویی تبدیل شدند و TechnologyBreadth تعداد فناوری‌های هر پاسخ‌دهنده را ثبت کرد. Employment به ۹ ویژگی چندبرچسبی و Country و RemoteWork به one-hot تبدیل شدند. ویژگی‌های عددی مشتق شده شامل تجربه توافقی، اختلاف سنج‌های تجربه، نسبت تجربه حرفه‌ای، اندازه سازمان لگاریتمی، indicatorهای گمشدگی و breadth حوزه‌ها هستند.

تعداد ویژگی	بلوک ویژگی
۲۶	numeric
۵۳	categorical_one_hot
۹	employment_multi_hot


تعداد ویژگی	بلوک ویژگی
۲۴۰	technology_multi_hot
۳۲۸	X_full_total
۲۴۱	X_tech_stack_total



شکل ۲ — فناوری‌های پرتکرار در cohort نهایی

Section ۵.۰۳. ۳.۳. مقیاس‌بندی

StandardScaler، MinMaxScaler و RobustScaler مقایسه شدند. ویژگی‌های تجربه و اندازه سازمان دنباله‌های بلند و پرت‌های واقعی دارند؛ از این رو RobustScaler که بر میانه و IQR متکی است به‌عنوان مسیر اصلی انتخاب شد. این انتخاب به معنی برتری مطلق نیست؛ در فاز سوم حساسیت برچسب نهایی به هر سه scaler با ARI سنجیده شد.




شکل ۳ — اثر سه روش مقیاس‌بندی بر هندسه ویژگی‌های عددی


Article VI. ۴. کاهش بعد، فاصله و گرایش خوشه‌ای

Section ۶.۰۱. ۴.۱. PCA، SVD و UMAP

PCA روی نمایش کامل Robust-scaled اجرا شد. ۵۰ مؤلفه ۷۷.۷۶٪ واریانس را حفظ کرد و فضای اصلی الگوریتم‌های فاصله‌محور شد. Truncated SVD روی نمایش sparse فناوری نیز ۶۹.۳۱٪ واریانس را نگه داشت. UMAP روی نمونه ثابت ۱۵,۰۰۰ تایی صرفاً برای تشخیص هندسه و هم‌پوشانی استفاده شد، نه برای برازش مدل نهایی.



شکل ۴ — واریانس تجمعی PCA و نقطه انتخاب ۵۰ مؤلفه



شکل ۵ — چگالی UMAP روی نمونه ثابت؛ ساختار پیوسته و هم‌پوشان

Section ۶.۰۲. ۴.۲. انتخاب معیار فاصله


Euclidean در فضای PCA معیار اصلی Ward، K-Means، و GMM است، زیرا مؤلفه‌ها عددی و متعامدند. برای نمایش فناوری دودویی، Jaccard مناسب‌تر است چون نبود مشترک فناوری نباید شباهت مثبت تولید کند. تحلیل حساسیت اجرا شده بر تعداد مؤلفه‌های PCA و سه روش مقیاس‌بندی تمرکز داشت؛ Jaccard نیز برای پایداری فناوری میان split استفاده شد. انتخاب metric بخشی از فرض مدل است.

Section ۶.۰۳. ۴.۳. VAT و Hopkins

نمایش	میانگین	انحراف معیار	کمینه	بیشینه
X_full_minmax	۰.۷۳۰۰	۰.۰۰۱۳	۰.۷۲۷۹	۰.۷۳۲۴
X_full_robust	۰.۷۷۸۷	۰.۰۰۱۳	۰.۷۷۶۳	۰.۷۸۰۷
X_full_standard	۰.۸۰۲۱	۰.۰۰۱۰	۰.۸۰۰۴	۰.۸۰۳۷
X_pca	۰.۸۵۴۸	۰.۰۰۱۱	۰.۸۵۳۱	۰.۸۵۶۶

نمایش	میانگین	انحراف معیار	کمینه	بیشینه
X_tech_stack	۰.۷۴۴۳	۰.۰۰۱۵	۰.۷۴۲۸	۰.۷۴۷۵

همه مقادیر Hopkins از ۰/۷ بالاترند و فرض تصادفی بودن کامل را تضعیف می کنند. باین حال VAT بلوک های کاملاً جدا نشان نمی دهد و UMAP نیز مرزهای نرم دارد. بنابراین داده واجد ساختار است، اما این ساختار الزاماً گروهی، کاملاً جدا یا دارای یک k بدیهی نیست.



شکل ۶ — ماتریس VAT بازمرتب شده روی نمونه هزار نفری PCA

Article VII. ۵. سبد الگوریتم ها و طراحی آزمایش

فاز دوم روی X_{pca} با ۵۰ بعد انجام شد. مسیر partitioning تمام ۶۰,۰۲۳ ردیف را برای ۱۰ مقدار k بررسی کرد. مقایسه بین خانواده ای برای جلوگیری از تفاوت نمونه روی یک نمونه ثابت ۳,۰۰۰ تایی با $seed=242$ انجام شد و ۷۸ پیکربندی را پوشش داد.

خانواده	روش‌ها	نقش در مقایسه
Partitioning	K-Means, MiniBatch K-Means	خط مبنا، مقیاس‌پذیر و کروی
Hierarchical	single, complete, average, Ward	بررسی ساختار تودرتو و linkage
Density-based	DBSCAN, HDBSCAN, OPTICS	خوشه‌های نامنظم و نویز
Model-based	GMM با چهار covariance	عضویت نرم و انتخاب AIC/BIC
Graph-based	Spectral nearest-neighbors	ساختار غیرکوژ روی گراف شباهت


قاعده کنترل کیفیت برای انتخاب نهایی، هر خوشه باید حداقل ۲٪ نمونه مشترک را شامل شود. این قاعده مانع انتخاب تقسیم‌های ظاهراً پر-silhouette اما بی‌معنا مانند single-linkage با خوشه تک‌عضوی شد.

Article VIII. انتخاب k و ارزیابی مقایسه‌ای


۸.۰.۱ Section ۶.۱. شواهد انتخاب k

معیار	k پیشنهادی	تفسیر
Silhouette	۲	جدایش کلی بهتر در تقسیم درشت
جمع رتبه‌های داخلی و پایداری	۲	مصالحه چندمعیاره
Elbow / Kneedle	۶	نقطه شکست inertia
Gap ۱-SE	۷	برتری نسبت به مرجع تصادفی
Bootstrap stability	۳	بالاترین ARI بازنمونه‌گیری
GMM BIC	۳	covariance کامل

معیارها پاسخ یکسانی ندادند و این موضوع با ساختار چندمقیاسی و هم‌پوشان داده سازگار است. $k=2$ یک خلاصه کلی و پایدار از پهنای پشته فناوری ارائه می‌کند، در حالی که kهای بزرگ‌تر جزئیات بیشتری را جدا می‌کنند. به همین دلیل تصمیم نهایی فقط بر یک معیار متکی نبود.



شکل ۷ — Elbow, silhouette و معیارهای انتخاب k برای partitioning




شکل ۸ — Gap Statistic و قاعده یک انحراف معیار

Section ۸.۰۲. مقایسه خانواده‌ها

خانواده	الگوریتم	k	Silhouette	DB	CH	زمان (ثانیه)
model_based	gmm_tied	۲	۰.۲۴۱	۱.۹۰۰	۲۹۳.۳	۰.۲۲
hierarchical	agglomerative_ward	۲	۰.۲۱۲	۲.۳۶۶	۳۴۳.۴	۰.۲۲
partitioning	kmeans	۲	۰.۱۹۱	۲.۳۵۸	۴۰۸.۹	۰.۰۸

خانواده	الگوریتم	k	Silhouette	DB	CH	زمان (ثانیه)
model_based	gmm_spherical	۲	۰.۱۵۴	۲.۹۲۱	۳۲۹.۶	۰.۲۰
spectral	spectral_nearest_neighbors	۳	۰.۱۲۱	۲.۰۰۷	۲۶۱.۹	۱.۶۶
partitioning	kmeans	۵	۰.۱۲۰	۲.۰۶۰	۳۰۷.۱	۰.۱۳
partitioning	kmeans	۳	۰.۱۱۹	۲.۳۱۳	۳۶۵.۷	۰.۱۳
spectral	spectral_nearest_neighbors	۴	۰.۱۱۸	۲.۰۶۶	۲۷۲.۸	۱.۴۶
partitioning	kmeans	۴	۰.۱۱۳	۲.۲۲۱	۳۳۳.۴	۰.۱۲
model_based	gmm_spherical	۳	۰.۱۱۱	۲.۳۲۷	۳۵۰.۲	۰.۰۹


بهترین silhouette معتبر بین خانواده‌ای به GMM با covariance tied و $k=2$ رسید؛ Ward با $k=2$ نیز نتیجه رقابتی داشت. بهترین BIC متعلق به GMM با covariance کامل و $k=3$ بود. روش‌های چگالی‌محور در grid مستندشده راه‌حل چندخوشه‌ای معتبر با سهم نويز و اندازه خوشه قابل قبول تولید نکردند؛ این نتیجه با پیوستگی و تغییر چگالی مشاهده‌شده در UMAP سازگار است.




شکل ۹ — مقایسه silhouette بهترین پیکربندی‌های معتبر هر خانواده

محدودیت	تعداد دسته	NMI	Proxy تفسیری
association only; proxy is not ground truth	۳۵	۰.۰۰۹۳	DevType
association only; proxy is not ground truth	۹	۰.۰۰۲۲	EdLevel
association only; proxy is not ground truth	۱۰۳	۰.۰۱۲۵	Employment
association only; proxy is not ground truth	۴	۰.۰۰۱۰	RemoteWork
association only; proxy is not ground truth	۴	۰.۰۰۳۹	AISelect

برای مرجع MiniBatch K-Means با $k=2$ ، میانگین ARI بیست seed برابر ۰.۵۸۳ و میانگین پایداری بیست bootstrap برابر ۰.۶۳۳ بود. این مقادیر پایداری متوسط را نشان می‌دهند و ضرورت تجمیع چند الگوریتم در consensus را تقویت می‌کنند. NMI پایین متغیرهای کمکی نیز نشان می‌دهد خوشه‌ها صرفاً بازسازی نقش یا تحصیلات نیستند.



شکل ۱۰ — پایداری bootstrap برای مقادیر مختلف k



شکل ۱۱ — توافق زوجی الگوریتم‌های نامزد با ARI

Article IX. ۷. مسیر پیشرفته اصلی: Consensus Clustering


Section ۹.۰۱ ۷.۱. ساخت ماتریس co-association

چهار نامزد Spectral-k^۳ و K-Means، Ward، GMM-full-k^۳ روی نمونه مشترک به ماتریس co-association تبدیل شدند. هر درایه نسبت مدلهایی است که یک زوج را هم‌خوشه می‌دانند. سپس Agglomerative با فاصله یک منهای co-association برای kهای ۲ تا ۶ اجرا شد. این روش وابستگی به یک هندسه یا تابع هدف منفرد را کاهش می‌دهد، هرچند کیفیت آن همچنان به تنوع و کیفیت اعضای ensemble وابسته است.

تعداد خوشه	کمترین سهم خوشه	Silhouette	k
۲	۲۱.۸٪	۰.۱۹۴۴	۲
۳	۷.۰٪	۰.۰۸۷۷	۳

تعداد خوشه	کمترین سهم خوشه	Silhouette	k
۴	۳.۰٪	۰.۰۵۵۲	۴
۵	۳.۰٪	۰.۰۵۱۳	۵
۶	۱.۶٪	۰.۰۳۱۰	۶

انتخاب نهایی $k=2$ با $silhouette=0.1944$ و رعایت حداقل سهم ۲٪ انتخاب شد. این انتخاب یک خلاصه دپروفایلی است و اختلاف شواهد k در فصل قبل عمداً در تفسیر حفظ می‌شود.



شکل ۱۲ — انتخاب k در فضای consensus


Section ۹.۰۲. ۷.۲. تعمیم به کل cohort

برچسب consensus مستقیماً برای نمونه ۳,۰۰۰ تایی تعریف شد. برای انتساب کل ۶۰,۰۲۳ ردیف، یک Random Forest متوازن روی ۵۰ مؤلفه PCA آموزش و با split طبقه‌بندی‌شده ارزیابی شد. دقت holdout برابر ۹۶.۴٪ بود. centroidهای consensus نیز برای انتساب زنده و محاسبه فاصله هر رکورد تا تمام خوشه‌ها ذخیره شدند.

Section ۱۰.۰۱ ۸.۱. پروفایل‌های نهایی

خوشه	نام پروفایل	تعداد	سهم	میانۀ تجربه	میانۀ breadth	نقش غالب
۰	Focused-stack practitioners	۴۵,۹۶۹	۷۶.۶٪	۸.۰	۱۴.۰	Developer, full-stack
۱	Broad-stack polyglots	۱۴,۰۵۴	۲۳.۴٪	۷.۵	۳۲.۰	Developer, full-stack

خوشه ۰ «کارورزان با پشته متمرکزتر» نام‌گذاری شد: سهم ۷۶/۶٪ و میانۀ ۱۴ فناوری. خوشه ۱ «توسعه‌دهندگان چندفناوری گسترده» است: سهم ۲۳/۴٪ و میانۀ ۳۲ فناوری. مرز اصلی یک طیف breadth است، نه تمایز ارزشی میان افراد. تفاوت نقش، تحصیلات، کشور و پذیرش AI برای غنی‌کردن تفسیر گزارش می‌شود، اما علت عضویت محسوب نمی‌شود.



شکل ۱۳ — اندازه و سهم دو پروفایل consensus

خوشه	حوزه	فناوری	پاسخ‌دهنده	درصد خوشه
۰	Language	JavaScript	۲۶,۱۲۰	۵۶.۸٪
۰	Language	HTML/CSS	۲۱,۸۵۷	۴۷.۵٪
۰	Language	SQL	۲۱,۰۹۰	۴۵.۹٪
۰	Language	Python	۲۰,۰۴۵	۴۳.۶٪
۰	ToolsTech	Docker	۱۸,۹۳۴	۴۱.۲٪
۰	ToolsTech	npm	۱۷,۲۸۷	۳۷.۶٪
۰	Database	PostgreSQL	۱۶,۶۰۲	۳۶.۱٪
۰	Language	TypeScript	۱۵,۰۲۱	۳۲.۷٪
۰	Platform	Amazon Web Services (AWS)	۱۴,۸۱۷	۳۲.۲٪
۰	Database	MySQL	۱۳,۳۰۸	۲۸.۹٪
۱	Language	JavaScript	۱۱,۳۷۲	۸۰.۹٪
۱	Language	Python	۱۰,۶۷۴	۷۵.۹٪
۱	ToolsTech	Docker	۱۰,۲۸۵	۷۳.۲٪
۱	Language	HTML/CSS	۹,۹۵۹	۷۰.۹٪
۱	Language	SQL	۹,۵۹۲	۶۸.۳٪
۱	ToolsTech	npm	۹,۵۷۹	۶۸.۲٪
۱	Database	PostgreSQL	۸,۹۳۴	۶۳.۶٪
۱	Webframe	Node.js	۸,۱۸۷	۵۸.۳٪

خوشه	حوزه	فناوری	پاسخ‌دهنده	درصد خوشه
۱	Language	TypeScript	۸,۱۲۹	۵۷.۸٪
۱	Language	Bash/Shell (all shells)	۷,۸۲۷	۵۵.۷٪

Section ۱۰.۰۳ ۸.۳. نمونه‌ها، قواعد و SHAP


برای هر خوشه سه نمونه ذخیره شد: medoid با کمترین مجموع فاصله درون خوشه‌ای، exemplar با بیشترین silhouette و boundary با کمترین silhouette. این نقاط امکان می‌دهند معنای مرکز، نمونه بسیار نماینده و ناحیه تردید هر پروفایل جداگانه بررسی شود.

خوشه	نوع نمونه	Responseld	Silhouette
۰	medoid	۴۶۹۷۲	۰.۳۴۲۱
۰	exemplar	۴۴۲۵۵	۰.۳۷۷۱
۰	boundary	۳۶۳۰۷	-۰.۰۴۱۹
۱	medoid	۲۸۴۶۴	۰.۰۸۴۳
۱	exemplar	۵۰۷۶۱	۰.۲۱۸۴
۱	boundary	۵۳۶۰۵	-۰.۱۷۱۱

درخت تصمیم عمق چهار عضویت را با fidelity برابر ۹۸.۹٪ روی holdout و ۹۸.۸٪ روی fit نهایی بازسازی کرد. SHAP نیز با وضعیت completed اجرا شد. چون ویژگی‌های ورودی درخت مؤلفه‌های PCA هستند، تفسیر SHAP باید همراه با loadings، پروفایل و فناوری‌های شاخص انجام شود.

ویژگی	اهمیت مدل	میانگین SHAP
PC۱	۰.۹۵۳۲	۰.۴۷۲۹
PC۳	۰.۰۴۵۵	۰.۰۲۳۸
PC۳۳	۰.۰۰۱۲	۰.۰۰۱۹
PC۲۲	۰.۰۰۰۰	۰.۰۰۰۱

ویژگی	اهمیت مدل	میانگین SHAP
PC۲	۰.۰۰۰۰	۰.۰۰۰۰
PC۴	۰.۰۰۰۰	۰.۰۰۰۰
PC۷	۰.۰۰۰۰	۰.۰۰۰۰
PC۸	۰.۰۰۰۰	۰.۰۰۰۰
PC۵	۰.۰۰۰۰	۰.۰۰۰۰
PC۶	۰.۰۰۰۰	۰.۰۰۰۰
PC۱۱	۰.۰۰۰۰	۰.۰۰۰۰
PC۱۲	۰.۰۰۰۰	۰.۰۰۰۰



شکل ۱۴ — اهمیت SHAP مؤلفه‌های مؤثر بر انتساب

Section ۱۱.۰۱ ۹.۱. مدل جبران خدمت

برای سنجش ارزش عملی خوشه‌ها، Random Forest روی log جبران خدمت یک‌بار به صورت سراسری و یک‌بار به صورت شرطی بر خوشه برازش شد. اگر خوشه‌ها ساختار پیش‌بینی‌پذیر مستقلی حمل می‌کردند، مدل‌های شرطی باید MAE کمتری می‌داشتند. این بهبود در هیچ خوشه‌ای رخ نداد.

مدل	خوشه	ردیف آزمون	MAE log	MAE مدل سراسری روی همان ردیف
global	all	۵۸۴۷	۰.۷۰۷۹	nan
cluster_conditional	۰	۴۴۲۹	۰.۷۰۹۷	۰.۶۹۷۶
cluster_conditional	۱	۱۴۱۸	۰.۷۴۵۹	۰.۷۴۰۰

نتیجه تحلیل جبران خدمت تقسیم consensus دقت پیش‌بینی جبران خدمت را بهتر نکرد. بنابراین نتایج این بخش، کاربرد پیش‌بینی مستقلی برای خوشه‌ها نشان نمی‌دهد.

Section ۱۱.۰۲ ۹.۲. تشخیص ناهنجاری خوشه‌محور

Isolation Forest با نرخ آلودگی یک درصد جداگانه در هر خوشه برازش شد و سپس یک درصد بالای امتیازها در کل cohort برای بازبینی ذخیره شد. ناهنجاری در اینجا به معنای فاصله از الگوی رایج همان خوشه است، نه خطا یا رفتار نامطلوب. این تعریف خوشه‌محور مانع از آن می‌شود که اعضای یک خوشه کوچک صرفاً به دلیل تفاوت کلی ناهنجار تلقی شوند.

خوشه	ResponseId	امتیاز ناهنجاری
۰	۵۷۷۳۸	۰.۶۰۰۳
۰	۲۴۷۴۲	۰.۵۹۳۸
۰	۵۶۲۵۹	۰.۵۷۷۲
۰	۴۹۹۳۷	۰.۵۷۱۰
۰	۶۲۲۳۰	۰.۵۷۰۹

خوشه	ResponseId	امتیاز ناهنجاری
۱	۶۳۵۲۱	۰.۶۹۴۹
۱	۵۳۴۷۰	۰.۶۷۵۲
۱	۲۶۶۷۸	۰.۶۷۳۰
۱	۲۲۶۲۸	۰.۶۷۲۹
۱	۴۸۵۶۳	۰.۶۷۲۹

Article XII. ۱۰. انصاف، composition و حساسیت

۱۰.۱. ممیزی composition

Section ۱۲.۰۱


ویژگی	خوشه	دسته غالب	سهم
AISelect	۱	Yes	۶۷.۲٪
AISelect	۰	Yes	۵۷.۲٪
EdLevel	۰	Bachelor's degree (B.A., B.S., B.Eng., etc.)	۴۰.۱٪
EdLevel	۱	Bachelor's degree (B.A., B.S., B.Eng., etc.)	۳۸.۷٪
RemoteWork	۱	Hybrid (some remote, some in-person)	۳۷.۲٪
RemoteWork	۰	Hybrid (some remote, some in-person)	۳۴.۹٪
Country	۰	United States of America	۱۸.۲٪
Country	۱	United States of America	۱۸.۲٪

تفاوت composition باید در تفسیر و استفاده احتمالی از مدل دیده شود. باین حال این جدول فقط توصیف همبستگی است؛ متغیرهای بررسی شده لزوماً sensitive attribute کامل یا علت عضویت نیستند. هیچ تصمیم فردی نباید صرفاً بر اساس شناسه خوشه گرفته شود.

Section ۱۲.۰۲ حساسیت به پیش‌پردازش ۱۰.۲

consensus به ARI نسبت	گونه آزمایش
۰.۹۳۹	PCA_۱۰
۰.۸۷۴	PCA_۲۰
۰.۸۴۰	PCA_۵۰
۰.۶۶۴	scaler_robust
۰.۳۱۴	scaler_minmax
۰.۲۶۲	scaler_standard

دامنه ARI از حدود ۰/۲۶ تا ۰/۹۴ نشان می‌دهد نمایش و scaler بخشی از پاسخ clustering هستند. PCA-۱۰ بیشترین توافق را داشت، در حالی که نمایش کامل Standard-scaled کمترین توافق را ایجاد کرد. این حساسیت ادعای «ذاتی‌بودن» دو خوشه را تضعیف می‌کند و ضرورت گزارش سناریوهای جایگزین را نشان می‌دهد.




شکل ۱۵ — حساسیت برچسب نهایی به نمایش، scaler و کاهش بعد

Section ۱۳.۰۱

۱۱.۱. NMF پربعد

NMF مستقیماً روی ۲۴۰ شاخص نامنفی فناوری اجرا شد تا ساختار اکوسیستم فناوری، مستقل از تقسیم breadth، بررسی شود. از میان ۲ تا ۶ مؤلفه، راه‌حل چهارمؤلفه‌ای با silhouette کسینوسی ۰.۰۹۸ انتخاب شد. ARI آن با consensus برابر ۰.۰۰۸- و NMI برابر ۰/۰۱۹ است؛ بنابراین دو مسیر ساختارهای مکمل می‌یابند.


انتخاب	ARI	کمترین سهم	Silhouette نهفته	Silhouette کسینوسی	مؤلفه
خیر	-۰.۰۴۳	۳۰.۹٪	۰.۲۹۸	۰.۰۷۰	۲
خیر	-۰.۰۲۵	۱۷.۰٪	۰.۱۷۴	۰.۰۵۵	۳
بله	-۰.۰۰۸	۱۷.۲٪	۰.۳۳۸	۰.۰۹۸	۴
خیر	-۰.۰۰۶	۱۵.۴٪	۰.۳۰۱	۰.۰۹۰	۵
خیر	۰.۰۰۳	۱۱.۱٪	۰.۲۶۹	۰.۰۸۳	۶



شکل ۱۶ — مقایسه تعداد مؤلفه‌ها در مسیر NMF

روش	برآورد	کران پایین ۹۵٪	کران بالا ۹۵٪
consensus	۰.۱۹۹۶	۰.۱۹۲۸	۰.۲۰۷۱
kmeans	۰.۱۹۷۱	۰.۱۸۹۳	۰.۲۰۳۶
agglomerative_ward	۰.۲۱۷۸	۰.۲۰۹۳	۰.۲۲۴۰
gmm_full_k۳	۰.۰۲۲۴	۰.۰۱۷۳	۰.۰۲۸۳
spectral_k۳	۰.۱۲۸۳	۰.۱۲۳۰	۰.۱۳۳۸
nmf_high_dimensional	۰.۰۰۹۲	۰.۰۰۵۳	۰.۰۱۳۲


با ۲۰۰ بازنمونه‌گیری برای پنج معیار و ۵,۰۰۰ جایگشت جفتی، روش agglomerative_ward نسبت به consensus اختلاف silhouette برابر ۰.۰۱۸۲ با $p=۰.۰۰۰۲$ داشت. معناداری آماری به‌تنهایی به معنای اهمیت عملی بزرگ نیست؛ اندازه اثر نیز گزارش شده است.



شکل ۱۷ — فاصله اطمینان bootstrap برای silhouette روش‌های نامزد

داده در میانه ExperienceConsensus=۸ به دو زیرجمعیت تقسیم و هر نیمه مستقل خوشه‌بندی شد. تطبیق prototype با الگوریتم Hungarian میانگین Jaccard فناوری ۰.۶۳۳ را نشان داد؛ پایداری متوسط است، نه یکسانی کامل. UMAP سه‌بعدی تعاملی نیز برای ۱۰,۰۰۰ پاسخ ساخته شد و در داشبورد و فایل HTML مستقل قرار دارد.

خوشه split اول	خوشه split دوم	ردیف اول	ردیف دوم	Jaccard فناوری
۰	۱	۱۳۱۸۷	۵۵۱۶	۰.۶۰۰
۱	۰	۱۸۶۴۹	۲۲۶۷۱	۰.۶۶۷



شکل ۱۸ — پایداری prototype میان دو نیمه تجربه

Article XIV

۱۲. خط تولید، بازتولیدپذیری و داشبورد

Section ۱۴.۰۱

۱۲.۱. معماری pipeline

خط تولید به مراحل ingest، clean، feature، scale، reduce، cluster و evaluate تفکیک شده است. خروجی هر مرحله در data/interim، data/processed یا artifacts ذخیره می‌شود و مرحله‌های پایین‌دستی می‌توانند بدون تکرار کل محاسبات اجرا شوند. schema ورودی کنترل، مدل‌ها با joblib سریال و manifest‌های ورودی و خروجی با SHA-۲۵۶ نسخه‌بندی شده‌اند.

لایه	خروجی اصلی	کاربرد
ورود و پاک‌سازی	Parquet میانی + manifest	ردیابی منبع و تصمیم‌های کیفیت

کاربرد	خروجی اصلی	لایه
نمایش کامل و فناوری	ماتریس‌های sparse + metadata	ویژگی
نمایش محاسباتی و بصری	PCA/SVD/UMAP + مدل	کاهش بعد
تحلیل و انتساب	labels, centroid, co-association	خوشه‌بندی
گزارش و audit	CSV/JSON + شکل	ارزیابی
استقرار و بازبینی	مدل، هش، پارامتر و scoreboard	Registry

Section ۱۴.۰۲ ۱۲.۲. پایش drift

هشدار	p-value	KS	PSI	ویژگی
False	۱.۴۳۳e-۲۹	۰.۰۴۷۳	۰.۰۱۲۱	PC۸
False	۷.۰۹۸e-۰۷	۰.۰۲۲۲	۰.۰۰۹۵	PC۲
False	۲.۴۳۷e-۱۵	۰.۰۳۳۸	۰.۰۰۷۴	PC۹
False	۲.۶۷۲e-۱۴	۰.۰۳۲۶	۰.۰۰۷۰	PC۱
False	۴.۹۳۷e-۱۸	۰.۰۳۶۷	۰.۰۰۶۷	PC۳
False	۲.۶۳۲e-۱۷	۰.۰۳۶۰	۰.۰۰۶۷	PC۱۰
False	۱.۹۵۴e-۱۴	۰.۰۳۲۸	۰.۰۰۶۴	PC۴
False	۶.۴۶۱e-۰۷	۰.۰۲۲۳	۰.۰۰۳۷	PC۶
False	۷.۳۸۲e-۰۶	۰.۰۲۰۴	۰.۰۰۳۱	PC۵
False	۰.۰۰۰۱۰۹۷	۰.۰۱۸۱	۰.۰۰۱۹	PC۷

baseline drift با دو نیمه ثابت داده برای ده مؤلفه نخست ساخته شد. PSI بزرگ‌تر از ۰/۲ یا KS بزرگ‌تر از ۰/۱ آستانه هشدار عملیاتی است. این baseline جایگزین داده زمانی واقعی نیست، اما قرارداد فنی لازم برای پایش نسخه‌های آینده را فراهم می‌کند.

داشبورد Streamlit پنج صفحه دارد: Overview، Cluster Explorer با UMAP دوبعدی و فیلتر تجربه/خوشه، Evaluation با معیارها و پایداری، Live Assignment برای رکورد یا CSV با فاصله تا تمام centroidها، و ۳D Explorer برای UMAP تعاملی دههزارنقطه‌ای. برچسب‌گذاری زنده فقط رکوردهای دارای PC۱ تا PC۵۰ را می‌پذیرد تا قرارداد پیش‌پردازش شفاف بماند.

```
python -m venv venv

.\venv\Scripts\python.exe -m pip install -r requirements.txt

.\venv\Scripts\python.exe -m scripts.run_all --config config.yaml

.\venv\Scripts\python.exe -m scripts.build_all_deliverables

powershell -ExecutionPolicy Bypass -File scripts\export_reports_pdf.ps1

.\venv\Scripts\python.exe -m scripts.validate_release

.\venv\Scripts\python.exe -m pytest -q
```

Article XV. ۱۳. بحث و محدودیت‌ها

- اختلاف Silhouette، Kneedle، Gap، BIC و bootstrap نشان می‌دهد k واحد و بدیهی وجود ندارد.
- Silhouette نهایی متوسط است و UMAP/VAT هم‌پوشانی پیوسته را نشان می‌دهند؛ مرزها قطعی نیستند.
- پاسخ به scaler و تعداد مؤلفه‌های PCA حساس است؛ بخشی از ساختار حاصل انتخاب نمایش است.
- پیمایش خوداظهاری، داوطلبانه و مقطعی است؛ نتیجه به کل جمعیت توسعه‌دهندگان یا سال‌های دیگر تعمیم قطعی ندارد.
- متغیرهای نقش، تحصیلات و AI برچسب مرجع نیستند و NMI پایین آن‌ها شکست مدل محسوب نمی‌شود.
- مدل‌های جبران خدمت شرطی بر خوشه بهتر نشدند؛ ارزش پایین دستی segmentation محدود است.
- تفسیر SHAP روی PCA غیرمستقیم است و باید همراه loadings و پروفایل فناوری خوانده شود.
- اعتبارسنجی انسانی و داده سال‌های بعد می‌تواند پایداری معنایی و زمانی پروفایل‌ها را بهتر ارزیابی کند.

محدوده کاربرد نتیجه خوشه‌ها برای اکتشاف، خلاصه‌سازی و تولید فرضیه مناسب‌اند. استفاده از آن‌ها برای قضاوت درباره صلاحیت، ارزش یا آینده یک فرد از داده و طراحی این مطالعه پشتیبانی نمی‌شود.

نتایج نشان داد داده ۲۰۲۴ Stack Overflow ساختار غیرتصادفی دارد، اما این ساختار چندمقیاسی و هم‌پوشان است. بررسی پنج خانواده الگوریتم، چند معیار k، پایداری و consensus به یک تقسیم دوپروفایلی رسید که عمدتاً breadth پشته فناوری را خلاصه می‌کند. پروفایل متمرکزتر اکثریت cohort و پروفایل چندفناوری گسترده اقلیت بزرگ آن را تشکیل می‌دهد. دقت بالای assigner و درخت توضیحی نشان می‌دهد این

تقسیم از نظر محاسباتی قابل بازتولید و توضیح است، اما silhouette متوسط، حساسیت پیش‌پردازش و نتیجه منفی مدل جبران خدمت مانع از ادعاهای قوی‌تر می‌شوند.

در کنار برچسب نهایی، فرایند کامل اجرا، خروجی‌های نسخه‌دار، مقایسه روش‌ها، تحلیل خطا و حساسیت، مسیر مکمل NMF، آزمون‌های آماری و داشبورد نیز تهیه شد. برای ادامه کار می‌توان همین فرایند را روی پیمایش سال‌های دیگر اجرا و تغییر توزیع داده و ثبات معنایی پروفایل‌ها را بررسی کرد.

Article XVII منابع

- [۱] Stack Overflow. Developer Survey ۲۰۲۴. <https://survey.stackoverflow.co/۲۰۲۴>
- [۲] Pedregosa, F. et al. Scikit-learn: Machine Learning in Python. JMLR, ۲۰۱۱
- [۳] Rousseeuw, P. J. Silhouettes: A Graphical Aid to Cluster Analysis. JCAM, ۱۹۸۷
- [۴] Ester, M. et al. A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases. KDD, ۱۹۹۶
- [۵] McInnes, L., Healy, J., Melville, J. UMAP: Uniform Manifold Approximation and Projection, ۲۰۱۸
- [۶] Monti, S. et al. Consensus Clustering: A Resampling-Based Method for Class Discovery. Machine Learning, ۲۰۰۳
- [۷] Lee, D. D., Seung, H. S. Learning the Parts of Objects by Non-negative Matrix Factorization. Nature, ۱۹۹۹
- [۸] Lundberg, S. M., Lee, S.-I. A Unified Approach to Interpreting Model Predictions. NeurIPS, ۲۰۱۷

Article XVIII پیوست الف — شبکه پارامترها

بخش	پارامتر	مقدار
عمومی	random_state	۴۲
ورود	chunk_size	۱۰۰۰۰
ویژگی	scaler اصلی	robust
کاهش بعد	PCA components	۵۰
UMAP	neighbors / min_dist	۳۰ / ۰.۰۵
Phase ۲	k values	۲, ۳, ۴, ۵, ۶, ۷, ۸, ۹, ۱۰, ۱۲
پایداری	seed / bootstrap	۲۰ / ۲۰

بخش	پارامتر	مقدار
مقایسه خانواده	sample / minimum share	۲۰٪ / ۳,۰۰۰
NMF	components	۲, ۳, ۴, ۵, ۶
Permutation	repeats	۵,۰۰۰

Article XIX پیوست ب — جدول کامل راه‌حل‌های برتر فاز دوم

خانواده	الگوریتم	k درخواستی	خوشه یافت‌شده	نویز	Silhouette	DB	CH
hierarchical	agglomerative_single	۲۰	۲	۰.۰٪	۰.۷۱۵۳	۰.۲۰۰۴	۲۳.۰
hierarchical	agglomerative_average	۲۰	۲	۰.۰٪	۰.۶۵۹۰	۰.۵۴۴۵	۳۰.۳
hierarchical	agglomerative_single	۳۰	۳	۰.۰٪	۰.۵۲۱۶	۰.۳۰۳۵	۱۵.۲
hierarchical	agglomerative_average	۳۰	۳	۰.۰٪	۰.۵۲۱۵	۰.۴۸۶۲	۱۸.۹
hierarchical	agglomerative_single	۴۰	۴	۰.۰٪	۰.۵۱۶۶	۰.۳۰۳۹	۱۳.۵
hierarchical	agglomerative_average	۴۰	۴	۰.۰٪	۰.۵۱۶۶	۰.۳۰۳۹	۱۳.۵
hierarchical	agglomerative_single	۵۰	۵	۰.۰٪	۰.۵۰۲۹	۰.۳۱۰۴	۱۲.۲
hierarchical	agglomerative_complete	۲۰	۲	۰.۰٪	۰.۴۳۳۵	۱.۱۹۳۸	۱۶۶.۳
hierarchical	agglomerative_single	۶۰	۶	۰.۰٪	۰.۴۳۱۱	۰.۳۴۱۴	۱۰.۸
hierarchical	agglomerative_single	۷۰	۷	۰.۰٪	۰.۴۲۶۷	۰.۳۴۷۵	۱۰.۰
hierarchical	agglomerative_single	۸۰	۸	۰.۰٪	۰.۴۲۶۰	۰.۳۵۰۵	۹.۶
hierarchical	agglomerative_complete	۳۰	۳	۰.۰٪	۰.۴۲۰۵	۰.۹۳۵۹	۸۸.۶
hierarchical	agglomerative_complete	۴۰	۴	۰.۰٪	۰.۴۱۷۳	۰.۸۲۲۴	۶۰.۹

خانواده	الگوریتم	k در خواستی	خوشه یافت شده	نویز	Silhouette	DB	CH
hierarchical	agglomerative_average	۵.۰	۵	۰.۰٪	۰.۳۷۵۰	۰.۸۵۲۸	۵۲.۳
hierarchical	agglomerative_average	۶.۰	۶	۰.۰٪	۰.۳۶۱۳	۱.۱۲۷۷	۴۴.۰
hierarchical	agglomerative_average	۷.۰	۷	۰.۰٪	۰.۲۷۰۲	۱.۱۴۹۸	۳۸.۹
hierarchical	agglomerative_average	۸.۰	۸	۰.۰٪	۰.۲۶۲۲	۱.۲۳۶۶	۳۵.۳
model_based	gmm_tied	۲.۰	۲	۰.۰٪	۰.۲۴۱۱	۱.۹۰۰۱	۲۹۳.۳
hierarchical	agglomerative_ward	۲.۰	۲	۰.۰٪	۰.۲۱۱۷	۲.۳۶۶۵	۳۴۳.۴
partitioning	kmeans	۲.۰	۲	۰.۰٪	۰.۱۹۱۴	۲.۳۵۸۱	۴۰۸.۹