

دانشگاه صنعتی خواجه نصیرالدین طوسی

دانشکده مهندسی کامپیوتر

گزارش فاز اول: آماده‌سازی داده و ارزیابی گرایش به خوشه‌بندی

تحلیل خوشه‌ای پروفایل توسعه‌دهندگان

مرصاد احمدی — علی حسن زاده

۴۰۳۰۴۴۶۴ — ۴۰۳۰۱۲۷۴

استاد: دکتر پیشگو

تیر ۱۴۰۵ / July ۲۰۲۶

فهرست مطالب	۲
چکیده اجرایی	۳
۱. داده و خط لوله ورود	۳
۲. پاک‌سازی و مدیریت نوع داده	۴
۳. مهندسی ویژگی	۶
۴. مقیاس‌بندی و انتخاب scaler	۷
۵. کاهش بعد	۸
۶. معیار فاصله و شباهت	۱۱
۷. ارزیابی گرایش به خوشه‌بندی	۱۱
۸. EDA خوشه‌محور	۱۳
۹. محدودیت‌ها و تصمیم ورود به فاز دوم	۱۵
پیوست الف — ثبت کامل تصمیم‌های پاک‌سازی	۱۶
پیوست ب — بازتولیدپذیری و اخلاق	۲۰


Article II. چکیده اجرایی

پیمایش ۲۰۲۴ Stack Overflow شامل ۶۵,۴۳۷ پاسخ‌دهنده و ۱۱۴ ستون خام است. پس از اعمال قواعد کیفیت و حذف ۵,۴۱۴ رکورد فاقد هرگونه شواهد پشته فناوری، cohort نهایی ۶۰,۰۲۳ پاسخ‌دهنده شد. دو نمایش اصلی ساخته شد: X_{full} با ۳۲۸ ویژگی و X_{tech_stack} با ۲۴۱ ویژگی. پنجاه مؤلفه PCA مقدار ۷۷.۸٪ واریانس را حفظ کرد. آزمون Hopkins در تمام نمایش‌ها بالاتر از ۰/۷ بود و وجود ساختار غیرتصادفی را تأیید کرد؛ در عین حال VAT و UMAP ساختاری پیوسته، هم‌پوشان و دارای تغییر چگالی را نشان دادند. بنابراین فاز دوم باید روش‌های partitioning، سلسله‌مراتبی، چگالی‌محور، مدل‌مبنا و spectral را به‌صورت مقایسه‌ای بررسی کند.

مقدار	شاخص کلیدی
۶۵,۴۳۷	پاسخ‌دهندگان خام
۶۰,۰۲۳	cohort پاک‌سازی‌شده
۳۲۸	ویژگی‌های X_{full}
۲۴۰	ویژگی‌های فناوری
۲۴۱	ویژگی‌های X_{tech_stack}
۷۷.۷۶٪	واریانس حفظ‌شده در PCA-۵۰

Article III. ۱. داده و خط لوله ورود

داده اصلی survey_results_public.csv و فرهنگ داده survey_results_schema.csv هستند. pipeline پیش از خواندن داده، وجود تمام ستون‌های موردنیاز و schema فایل فرهنگ را کنترل می‌کند، فایل ۱۵۹ مگابایتی را در chunkهای ده‌هزارردیفی می‌خواند و نسخه منتخب را در قالب Parquet ذخیره می‌کند. برای داده خام، schema و خروجی میانی هش ۲۵۶-SHA ثبت شده است تا هر اجرای آینده قابل ردیابی باشد. از ۱۸ متغیر تحلیلی طرح اولیه، چهار متغیر AISelect، EdLevel، DevType و ConvertedCompYearly فقط برای تفسیر/تحلیل پایین‌دستی نگه داشته شدند. این جداسازی از ارزیابی دوری جلوگیری می‌کند. چهارده متغیر باقی‌مانده شامل تجربه، اندازه سازمان، وضعیت اشتغال، دورکاری، کشور و هفت حوزه فناوری هستند. Responseld، MainBranch و Check نیز صرفاً برای کنترل داده وارد شدند.



شکل ۱ — درصد داده گمشده در ستون‌های منتخب پیش از پاک‌سازی

Article IV. ۲. پاک‌سازی و مدیریت نوع داده

در داده هیچ شناسه تکراری و هیچ شکست صریح آزمون توجه وجود نداشت. تعداد ۱۳۸ کشور با فراوانی کمتر از ۲۰۰ در گروه **Other** قرار گرفتند. رشته‌های تجربه به سال عددی تبدیل شدند؛ «کمتر از یک سال» برابر ۰/۵ و «بیش از ۵۰ سال» برابر ۵۱ در نظر گرفته شد. **Missing** تجربه با میانه همان گروه کشور و سپس میانه سراسری تکمیل شد، اما **indicator** گمشدگی حفظ گردید. اندازه سازمان به **midpoint** بازه نگاشت و **log_{۱۰}p** شد. جبران خدمت فقط متغیر مکمل است و مقادیر غیرمثبت آن حذف می‌شوند.

ردیف متاثر	اقدام	مسئله	ستون
۳۵۷۷۹	country-median imputation with global median fallback; retain WorkExpNumericMissing	missing experience	WorkExpNumeric
۱۷۹۵۷	map ranges to midpoints, median-impute unknowns, then log _{۱۰} p	ordinal ranges and missing/unknown values	OrgSize

ردیف متاثر	اقدام	مسئله	ستون
۱۳۸۲۷	country-median imputation with global median fallback; retain YearsCodeProNumericMissing	missing experience	YearsCodeProNumeric
۵۵۶۸	country-median imputation with global median fallback; retain YearsCodeNumericMissing	missing experience	YearsCodeNumeric
۵۴۱۴	exclude rows with all seven domains missing	no response in all seven technology domains	technology matrix
۵۳۰۱	group countries with fewer than ۲۰۰ respondents as Other	high cardinality / rare categories	Country
۲۳۸۸	strip text and map empty strings to missing	whitespace/type consistency	MiscTechHaveWorkedWith
.	strip text and map empty strings to missing	whitespace/type consistency	YearsCode
.	strip text and map empty strings to missing	whitespace/type consistency	MainBranch
.	strip text and map empty strings to missing	whitespace/type consistency	Employment

Experience distributions before imputation




شکل ۲ — توزیع سه سنجه تجربه پیش از imputation

هفت ستون فناوری با جداکننده semicolon شکافته و بدون حذف هیچ فناوری به ۲۴۰ ویژگی multi-hot تبدیل شدند. یک ویژگی TechnologyBreadth مجموع فناوری‌های پاسخ‌دهنده را ثبت می‌کند؛ بنابراین X_tech_stack دقیقاً ۲۴۱ ویژگی دارد. Employment نیز به ۹ ویژگی multi-hot تبدیل شد. Country و RemoteWork به one-hot تبدیل شدند.

ویژگی‌های عددی مشتق‌شده شامل سه تجربه تکمیل‌شده، میانه توافقی تجربه، اختلاف سنج‌های تجربه، نسبت تجربه حرفه‌ای به کل، log اندازه سازمان، indicatorهای گمشدگی و breadth هر حوزه فناوری است. ترکیب این بلوک با متغیرهای دودویی، X_full با ۳۲۸ ویژگی را ساخته است.

تعداد	بلوک ویژگی
۲۶	numeric
۵۳	categorical_one_hot
۹	employment_multi_hot
۲۴۰	technology_multi_hot
۳۲۸	X_full_total
۲۴۱	X_tech_stack_total



شکل ۳ — ۲۵ فناوری پرتکرار در cohort نهایی


Article VI. ۴. مقیاس‌بندی و انتخاب scaler

StandardScaler، RobustScaler و MinMaxScaler روی بلوک عددی مقایسه شدند؛ ویژگی‌های one-hot/multi-hot به‌صورت دودویی باقی ماندند. نمودار قبل/بعد نشان می‌دهد هر سه روش هندسه را به‌شدت تغییر می‌دهند. داده تجربه و اندازه سازمان دارای دنباله‌های بلند و پرت‌های واقعی است؛ بنابراین RobustScaler با center میانه و IQR به‌عنوان انتخاب اصلی قفل شد.

نمایش	میانگین Hopkins	انحراف معیار
X_full_minmax	۰.۷۳۰۰	۰.۰۰۱۳
X_full_robust	۰.۷۷۸۷	۰.۰۰۱۳
X_full_standard	۰.۸۰۲۱	۰.۰۰۱۰

StandardScaler مقدار Hopkins بالاتری دارد، اما Hopkins معیار کیفیت خوشه‌بندی یا تابع هدف انتخاب scaler نیست؛ فقط فاصله از تصادفی‌بودن را می‌سنجد و به تغییر هندسه حساس است. انتخاب Robust بر مقاومت در برابر tailهای تجربه/اندازه سازمان مبتنی است. در فاز سوم حساسیت clustering نهایی به هر سه scaler با ARI گزارش خواهد شد.


Geometry of two features before and after scaling




شکل ۴ — هندسه تجربه و اندازه سازمان پیش و پس از سه روش مقیاس‌بندی

Article VII. ۵. کاهش بعد


PCA روی X_{full} مبتنی بر RobustScaler اجرا شد. پنجاه مؤلفه ۷۷.۷۶٪ واریانس را حفظ کردند؛ ۸ مؤلفه نخست از ۵۰٪ و ۳۰ مؤلفه از ۷۰٪ عبور می‌کنند. انتخاب ۵۰ مؤلفه با طرح اولیه سازگار است و مصالحه‌ای میان حفظ اطلاعات و کاهش تمرکز فاصله‌ها فراهم می‌کند. برای ماتریس sparse فناوری نیز Truncated SVD، پنجاه‌بعدی، ۶۹.۳۱٪ واریانس را نگه داشت. UMAP روی نمونه ثابت ۱۵,۰۰۰ تایی برای تشخیص کیفی ساختار اجرا شد و ورودی نهایی الگوریتم‌های فاصله‌محور نیست.



شکل ۵ — منحنی واریانس تجمعی PCA



شکل ۶ — چگالی پاسخ‌دهندگان در دو مؤلفه نخست PCA



شکل ۷ — نمایش غیرخطی UMAP روی نمونه ثابت ۱۵ هزار تایی

Article VIII. ۶. معیار فاصله و شباهت


فاصله Euclidean در فضای PCA مقیاس شده معیار اصلی Ward، K-Means و GMM است، زیرا مؤلفه‌ها متعامد و عددی‌اند. Manhattan و Gower در طراحی اولیه به عنوان گزینه‌های جایگزین بررسی شدند، اما مقایسه نهایی خانواده‌ها برای حفظ هندسه و نمونه مشترک بر Euclidean در فضای PCA ثابت شد. Jaccard نیز فقط در سنجش پایداری واژگان فناوری میان دو split تجربه به کار رفت.

Article IX. ۷. ارزیابی گرایش به خوشه‌بندی

Hopkins در ده تکرار با seedهای ثبت شده و نمونه ۱۵۰۰ تایی محاسبه شد. تمام میانگین‌ها از ۰/۷ بیشترند و به ویژه PCA گرایش قوی ۰/۸۵۵ را نشان می‌دهد. انحراف معیارهای نزدیک ۰/۰۰۱ نشان می‌دهد نتیجه به نمونه تصادفی خاص وابسته نیست.

نمایش	میانگین	انحراف معیار	کمینه	بیشینه
X_full_minmax	۰.۷۳۰۰	۰.۰۰۱۳	۰.۷۲۷۹	۰.۷۳۲۴
X_full_robust	۰.۷۷۸۷	۰.۰۰۱۳	۰.۷۷۶۳	۰.۷۸۰۷

نمایش	میانگین	انحراف معیار	کمینه	بیشینه
X_full_standard	۰.۸۰۲۱	۰.۰۰۱۰	۰.۸۰۰۴	۰.۸۰۳۷
X_pca	۰.۸۵۴۸	۰.۰۰۱۱	۰.۸۵۳۱	۰.۸۵۶۶
X_tech_stack	۰.۷۴۴۳	۰.۰۰۱۵	۰.۷۴۲۸	۰.۷۴۷۵




شکل ۸ — ماتریس عدم شباهت بازمرتب شده با VAT روی نمونه هزار نفری PCA


VAT بلوک‌های کاملاً جدا و مربعی نشان نمی‌دهد؛ به جای آن گرادیان‌ها و نواحی پیوسته دیده می‌شود. این نتیجه با UMAP سازگار است: ساختار واقعی وجود دارد، اما احتمالاً شامل manifold، overlap و تغییر چگالی است. بنابراین نباید یک پاسخ K-Means را بدون مقایسه HDBSCAN، Spectral، GMM و روش سلسله‌مراتبی به عنوان حقیقت طبیعی پذیرفت.

حوزه	فناوری	پاسخ‌دهنده	درصد cohort
Language	JavaScript	۳۷۴۹۲	۶۲.۴۶٪
Language	HTML/CSS	۳۱۸۱۶	۵۳.۰۱٪
Language	Python	۳۰۷۱۹	۵۱.۱۸٪
Language	SQL	۳۰۶۸۲	۵۱.۱۲٪
ToolsTech	Docker	۲۹۲۱۹	۴۸.۶۸٪
ToolsTech	npm	۲۶۸۶۶	۴۴.۷۶٪
Database	PostgreSQL	۲۵۵۳۶	۴۲.۵۴٪
Language	TypeScript	۲۳۱۵۰	۳۸.۵۷٪
Platform	Amazon Web Services (AWS)	۲۲۱۹۱	۳۶.۹۷٪
Database	MySQL	۲۱۰۹۹	۳۵.۱۵٪
Language	Bash/Shell (all shells)	۲۰۴۱۲	۳۴.۰۱٪
Webframe	Node.js	۱۹۷۷۲	۳۲.۹۴٪

JavaScript، HTML/CSS، Python و SQL هر یک در بیش از نیمی از cohort دیده می‌شوند؛ بنابراین به‌تنهایی جداکننده کافی نیستند. ترکیب فناوری‌ها، breadth، تجربه و context کاری برای ساخت persona اهمیت بیشتری دارد. ماتریس Spearman و Cramér's V نیز برای کنترل هم‌خطی و ارتباط متغیرهای رده‌ای تولید و در بسته artifact ذخیره شده است.



شکل ۹ — همبستگی Spearman ویژگی‌های عددی مهندسی شده



شکل ۱۰ — ارتباط رده‌ای با Cramér's V اصلاح‌شده

Article XI. ۹. محدودیت‌ها و تصمیم ورود به فاز دوم

- گمشدگی WorkExp و برخی حوزه‌های فناوری بالاست؛ indicator گمشدگی حفظ شده، اما imputation همچنان عدم قطعیت ایجاد می‌کند.
 - Hopkins قوی وجود ساختار غیرتصادفی را نشان می‌دهد، نه تعداد یا معنای خوشه‌ها را.
 - PCA-۵۰ حدود ۲۲/۲٪ واریانس را حذف می‌کند؛ نتایج بر X_{full} و X_{tech_stack} نیز برای حساسیت مقایسه می‌شوند.
 - DevType، EdLevel و AISelect برچسب مرجع نیستند و فقط متغیرهای کمکی برای تفسیرند؛ معیارهای خارجی با این محدودیت گزارش می‌شوند.
- نتایج فاز اول ادامه تحلیل خوشه‌ای را توجیه می‌کند. در فاز دوم k با BIC، Elbow/Kneedler، Silhouette، Gap، DB/CH/Dunn بررسی می‌شود و پایداری seed/bootstrap همراه با توافق الگوریتم‌ها سنجیده خواهد شد.

Article XII. پیوست الف — ثبت کامل تصمیم‌های پاک‌سازی

ردیف متاثر	توجیه	اقدام	مسئله	ستون
.	Prevents duplicate categories caused by formatting drift.	strip text and map empty strings to missing	whitespace/type consistency	MainBranch
.	Prevents duplicate categories caused by formatting drift.	strip text and map empty strings to missing	whitespace/type consistency	Employment
.	Prevents duplicate categories caused by formatting drift.	strip text and map empty strings to missing	whitespace/type consistency	RemoteWork
.	Prevents duplicate categories caused by formatting drift.	strip text and map empty strings to missing	whitespace/type consistency	Check
.	Prevents duplicate categories caused by formatting drift.	strip text and map empty strings to missing	whitespace/type consistency	EdLevel
.	Prevents duplicate categories caused by formatting drift.	strip text and map empty strings to missing	whitespace/type consistency	YearsCode

ردیف متاثر	توجیه	اقدام	مسئله	ستون
.	Prevents duplicate categories caused by formatting drift.	strip text and map empty strings to missing	whitespace/type consistency	YearsCodePro
.	Prevents duplicate categories caused by formatting drift.	strip text and map empty strings to missing	whitespace/type consistency	DevType
.	Prevents duplicate categories caused by formatting drift.	strip text and map empty strings to missing	whitespace/type consistency	OrgSize
.	Prevents duplicate categories caused by formatting drift.	strip text and map empty strings to missing	whitespace/type consistency	Country
.	Prevents duplicate categories caused by formatting drift.	strip text and map empty strings to missing	whitespace/type consistency	LanguageHaveWorkedWith
.	Prevents duplicate categories caused by formatting drift.	strip text and map empty strings to missing	whitespace/type consistency	DatabaseHaveWorkedWith
.	Prevents duplicate categories caused by formatting drift.	strip text and map empty strings to missing	whitespace/type consistency	PlatformHaveWorkedWith

ردیف متاثر	توجیه	اقدام	مسئله	ستون
.	Prevents duplicate categories caused by formatting drift.	strip text and map empty strings to missing	whitespace/type consistency	WebframeHaveWorkedWith
.	Prevents duplicate categories caused by formatting drift.	strip text and map empty strings to missing	whitespace/type consistency	EmbeddedHaveWorkedWith
۲۳۸۸	Prevents duplicate categories caused by formatting drift.	strip text and map empty strings to missing	whitespace/type consistency	MiscTechHaveWorkedWith
.	Prevents duplicate categories caused by formatting drift.	strip text and map empty strings to missing	whitespace/type consistency	ToolsTechHaveWorkedWith
.	Prevents duplicate categories caused by formatting drift.	strip text and map empty strings to missing	whitespace/type consistency	AISelect
.	Duplicate records artificially inflate local density.	keep first occurrence	duplicate respondents	ResponseId
.	Explicit failures indicate unreliable responses; missing is not assumed failure.	exclude explicit failures; retain missing checks	failed attention check	Check

ردیف متاثر	توجیه	اقدام	مسئله	ستون
۵۳۰۱	Limits sparse one-hot dimensions while retaining common geographic context.	group countries with fewer than ۲۰۰ respondents as Other	high cardinality / rare categories	Country
.	A continuous experience scale is required for distance-based clustering.	parse to YearsCodeNumeric; Less than ۱ year=۰.۵, More than ۵۰ years=۵۱	numeric values stored as strings and boundary labels	YearsCode
.	A continuous experience scale is required for distance-based clustering.	parse to YearsCodeProNumeric; Less than ۱ year=۰.۵, More than ۵۰ years=۵۱	numeric values stored as strings and boundary labels	YearsCodePro
۵۵۶۸	Missingness is preserved explicitly and imputation avoids artificial zero-experience clusters.	country-median imputation with global median fallback; retain YearsCodeNumericMissing	missing experience	YearsCodeNumeric
۱۳۸۲۷	Missingness is preserved explicitly and imputation avoids artificial zero-experience clusters.	country-median imputation with global median fallback; retain YearsCodeProNumericMissing	missing experience	YearsCodeProNumeric

ردیف متاثر	توجیه	اقدام	مسئله	ستون
۳۵۷۷۹	Missingness is preserved explicitly and imputation avoids artificial zero-experience clusters.	country-median imputation with global median fallback; retain WorkExpNumericMissing	missing experience	WorkExpNumeric
۱۷۹۵۷	Preserves order while reducing the extreme range of organisation sizes.	map ranges to midpoints, median-impute unknowns, then log _{1p}	ordinal ranges and missing/unknown values	OrgSize
۵۴۱۴	The research question cannot be answered without any technology-stack evidence.	exclude rows with all seven domains missing	no response in all seven technology domains	technology matrix
.	Compensation is supplementary and invalid values must not distort downstream regression.	set to missing; exclude from clustering feature space	non-positive compensation	ConvertedCompYearly

Article XIII. پیوست ب — بازتولیدپذیری و اخلاق

تمام روش‌های تصادفی seed پایه ۴۲ دارند. مسیرها و پارامترها از config.yaml خوانده می‌شوند و اجرای کامل فاز با فرمان زیر امکان‌پذیر است:

```
.\venv\Scripts\python.exe -m scripts.run_phase\ --config config.yaml
```

منبع داده ۲۰۲۴ Stack Overflow Developer Survey است. داده فقط برای تحلیل دانشگاهی استفاده شده و هیچ شناسایی فردی انجام نشده است.