

دانشگاه صنعتی خواجه نصیرالدین طوسی

دانشکده مهندسی کامپیوتر

گزارش فاز سوم پروژه داده‌کاوی پیشرفته

Consensus، پروفایل‌سازی، توضیح‌پذیری و تحلیل پیشرفته

مرصاد احمدی — علی حسن زاده

۴۰۳۰۴۴۶۴ — ۴۰۳۰۱۲۷۴

استاد: دکتر پیشگو

تیر ۱۴۰۵ / July ۲۰۲۶

|         |                                   |
|---------|-----------------------------------|
| ۲.....  | فهرست مطالب                       |
| ۳.....  | چکیده اجرایی                      |
| ۳.....  | ۱. ساخت Consensus Clustering      |
| ۳.....  | ۱.۱. منطق ensemble                |
| ۴.....  | ۲. تعمیم برچسب و مدل انتساب       |
| ۵.....  | ۳. پروفایل های انسانی             |
| ۶.....  | ۴. فناوری های متمایزکننده         |
| ۸.....  | ۵. Medoid، exemplar و boundary    |
| ۸.....  | ۶. قواعد توضیحی و SHAP            |
| ۱۰..... | ۷. تحلیل پایین دستی جبران خدمت    |
| ۱۱..... | ۸. ناهنجاری خوشه محور             |
| ۱۲..... | ۹. ممیزی composition و انصاف      |
| ۱۲..... | ۱۰. حساسیت و استحکام              |
| ۱۳..... | ۱۱. Registry، نسخه بندی و drift   |
| ۱۴..... | ۱۲. مسیر دوم: NMF پربعد           |
| ۱۵..... | ۱۳. استنباط آماری و پایداری split |
| ۱۵..... | ۱۳.۱. permutation و Bootstrap     |
| ۱۶..... | ۱۳.۲. پایداری بین دو نیمه تجربه   |
| ۱۷..... | ۱۴. داشبورد و خروجی عملیاتی       |
| ۱۷..... | ۱۵. محدودیت ها و نتیجه            |
| ۱۸..... | منابع                             |

در فاز سوم چهار نامزد مکمل K-Means، Ward، GMM-full-k<sup>۳</sup> و Spectral-k<sup>۳</sup> در یک ماتریس co-association تجمیع شدند. برش Agglomerative در فضای consensus مقدار k=۲ را انتخاب کرد. برچسب نمونه مشترک با یک assigner متوازن به تمام ۶۰'۰۲۳ پاسخ تعمیم یافت و دقت holdout آن ۹۶.۴٪ بود. درخت توضیحی نیز fidelity برابر ۹۸.۹٪ به دست آورد.

دو پروفایل نهایی ۴۵,۹۶۹ و ۱۴,۰۵۴ عضو دارند و تفاوت اصلی آن‌ها پهنای پشته فناوری با میانه‌های ۱۴ و ۳۲ فناوری است. مدل‌های جبران خدمت شرطی بر خوشه نسبت به مدل سراسری بهتر نشدند و تحلیل حساسیت، وابستگی قابل توجه برچسب‌ها به scaler و نمایش را نشان داد. مسیر دوم NMF چهار اکوسیستم فناوری با ARI نزدیک صفر نسبت به consensus یافت؛ بنابراین ساختار فناوری محور و تقسیم breadth مکمل‌اند.

نتیجه تفسیری Consensus یک خلاصه قابل توضیح از طیف breadth فناوری است، نه کشف دو نوع ذاتی توسعه‌دهنده. هم‌پوشانی، حساسیت و نتیجه تحلیل پایین‌دستی نیز باید هنگام ارائه یا استفاده از خوشه‌ها در نظر گرفته شود.

| مقدار                        | شاخص               |
|------------------------------|--------------------|
| K-Means، Ward، GMM، Spectral | نامزدهای consensus |
| ۲                            | k نهایی            |
| ۴۵,۹۶۹ / ۱۴,۰۵۴              | اندازه خوشه‌ها     |
| ۹۶.۴٪                        | دقت assigner       |
| ۹۸.۹٪                        | Fidelity درخت      |
| NMF با ۴ مؤلفه               | مسیر دوم           |


## Article III. ۱. ساخت Consensus Clustering

### ۳.۰۱ Section ۱.۱. منطق ensemble

نتایج فاز دوم نشان دادند معیارهای k و خانواده‌های الگوریتم توافق کامل ندارند. به جای انتخاب یک مدل منفرد، برای هر زوج پاسخ‌دهنده نسبت الگوریتم‌هایی که آن دو را هم‌خوشه می‌دانند محاسبه شد. این co-association نتیجه الگوریتم‌هایی با فرض‌های متفاوت را جمع می‌کند و وابستگی به هندسه کروی، سلسله‌مراتبی، احتمالاتی یا گرافی منفرد را کاهش می‌دهد.

فاصله consensus برابر یک منهای co-association تعریف و Agglomerative با average linkage برای kهای ۲ تا ۶ اجرا شد. همان قاعده حداقل سهم ۲٪ حفظ شد تا پاسخ‌های منحن انتخاب نشوند. Silhouette در فضای PCA مشترک برای مقایسه برش‌ها استفاده شد.

| خوشه واقعی | کمترین سهم | Silhouette | k |
|------------|------------|------------|---|
| ۲          | ۲۱.۸٪      | ۰.۱۹۴۴     | ۲ |
| ۳          | ۷.۰٪       | ۰.۰۸۷۷     | ۳ |
| ۴          | ۳.۰٪       | ۰.۰۵۵۲     | ۴ |
| ۵          | ۳.۰٪       | ۰.۰۵۱۳     | ۵ |
| ۶          | ۱.۶٪       | ۰.۰۳۱۰     | ۶ |



شکل ۱ — انتخاب تعداد خوشه در فضای consensus

## Article IV. ۲. تعمیم برچسب و مدل انتساب

ماتریس co-association فقط روی نمونه مشترک ۳۰۰۰ تایی قابل محاسبه بود. برای تعمیم، Random Forest متوازن روی ۵۰ مؤلفه PCA آموزش دید و با split طبقه‌بندی‌شده ارزیابی شد. دقت ۹۶/۴٪ نشان می‌دهد مرز consensus در فضای PCA قابل تقریب است، اما assigner جایگزین تعریف اصلی consensus نیست و فقط قرارداد عملیاتی انتساب را فراهم می‌کند.


پس از ارزیابی، مدل روی کل نمونه consensus بازبرازش و برای تمام cohort پیش‌بینی شد. centroid هر خوشه نیز ذخیره شد تا داشبورد برای رکورد جدید علاوه بر برجسب، فاصله تا تمام centroidها را نمایش دهد. این فاصله شاخص عدم قطعیت نسبی است و probability کالبره شده نیست.

کنترل تعمیم دقت holdout assigner برابر ۹۶.۴٪ است. این عدد روی داده نگه‌داشته شده محاسبه شده و از دقت آموزش درخت توضیحی جدا نگه داشته شده است.

## Article V. ۳. پروفایل‌های انسانی

| خوشه | پروفایل                     | تعداد  | سهم   | تجربه میانه | Breadth میانه | نقش غالب              |
|------|-----------------------------|--------|-------|-------------|---------------|-----------------------|
| ۰    | Focused-stack practitioners | ۴۵,۹۶۹ | ۷۶.۶٪ | ۸.۰         | ۱۴.۰          | Developer, full-stack |
| ۱    | Broad-stack polyglots       | ۱۴,۰۵۴ | ۲۳.۴٪ | ۷.۵         | ۳۲.۰          | Developer, full-stack |

خوشه ۰ با ۷۶/۶٪ cohort و میانه ۱۴ فناوری «پشته متمرکزتر» نام گرفت. خوشه ۱ با ۲۳/۴٪ و میانه ۳۲ فناوری «چندفناوری گسترده» است. این نام‌ها بر ویژگی غالب breadth متکی‌اند. تفاوت تجربه و نقش به تفسیر کمک می‌کند، اما نام‌گذاری نباید به سلسله‌مراتب ارزشی میان توسعه‌دهندگان تبدیل شود.



شکل ۲ — اندازه و سهم دو پروفایل consensus

## Article VI. ۴. فناوری‌های متمایزکننده

برای هر یک از هفت حوزه فناوری، فراوانی گزینه‌ها در هر خوشه محاسبه و هشت فناوری شاخص ذخیره شد. فناوری‌های عمومی مانند JavaScript، HTML/CSS، SQL و Python در هر دو گروه دیده می‌شوند؛ تفاوت اصلی در تعداد و هم‌وقوعی فناوری‌ها است. پروفایل گسترده‌تر سهم بالاتری از ابزارها، پلتفرم‌ها و چارچوب‌های هم‌زمان دارد.

| خوشه | حوزه      | فناوری     | پاسخ‌دهنده | درصد خوشه |
|------|-----------|------------|------------|-----------|
| •    | Language  | JavaScript | ۲۶,۱۲۰     | ۵۶.۸٪     |
| •    | Language  | HTML/CSS   | ۲۱,۸۵۷     | ۴۷.۵٪     |
| •    | Language  | SQL        | ۲۱,۰۹۰     | ۴۵.۹٪     |
| •    | Language  | Python     | ۲۰,۰۴۵     | ۴۳.۶٪     |
| •    | ToolsTech | Docker     | ۱۸,۹۳۴     | ۴۱.۲٪     |
| •    | ToolsTech | npm        | ۱۷,۲۸۷     | ۳۷.۶٪     |

| خوشه | حوزه      | فناوری                    | پاسخ‌دهنده | درصد خوشه |
|------|-----------|---------------------------|------------|-----------|
| ۰    | Database  | PostgreSQL                | ۱۶,۶۰۲     | ۳۶.۱٪     |
| ۰    | Language  | TypeScript                | ۱۵,۰۲۱     | ۳۲.۷٪     |
| ۰    | Platform  | Amazon Web Services (AWS) | ۱۴,۸۱۷     | ۳۲.۲٪     |
| ۰    | Database  | MySQL                     | ۱۳,۳۰۸     | ۲۸.۹٪     |
| ۰    | Language  | Bash/Shell (all shells)   | ۱۲,۵۸۵     | ۲۷.۴٪     |
| ۰    | Webframe  | React                     | ۱۲,۰۱۹     | ۲۶.۱٪     |
| ۱    | Language  | JavaScript                | ۱۱,۳۷۲     | ۸۰.۹٪     |
| ۱    | Language  | Python                    | ۱۰,۶۷۴     | ۷۵.۹٪     |
| ۱    | ToolsTech | Docker                    | ۱۰,۲۸۵     | ۷۳.۲٪     |
| ۱    | Language  | HTML/CSS                  | ۹,۹۵۹      | ۷۰.۹٪     |
| ۱    | Language  | SQL                       | ۹,۵۹۲      | ۶۸.۳٪     |
| ۱    | ToolsTech | npm                       | ۹,۵۷۹      | ۶۸.۲٪     |
| ۱    | Database  | PostgreSQL                | ۸,۹۳۴      | ۶۳.۶٪     |
| ۱    | Webframe  | Node.js                   | ۸,۱۸۷      | ۵۸.۳٪     |
| ۱    | Language  | TypeScript                | ۸,۱۲۹      | ۵۷.۸٪     |
| ۱    | Language  | Bash/Shell (all shells)   | ۷,۸۲۷      | ۵۵.۷٪     |
| ۱    | Database  | MySQL                     | ۷,۷۹۱      | ۵۵.۴٪     |
| ۱    | ToolsTech | Pip                       | ۷,۷۷۸      | ۵۵.۳٪     |

## Article VII. ۵. boundary و Medoid, exemplar

Medoid دقیق با کمینه کردن مجموع فاصله‌های درون خوشه‌ای در نمونه consensus تعیین شد. exemplar بیشترین silhouette و boundary کمترین silhouette را دارد. medoid تصویر مرکز واقعی، exemplar نمونه بسیار نماینده و boundary ناحیه ابهام بین پروفایل‌ها را نشان می‌دهد. Responseld برای بازبینی این نمونه‌ها در notebook ذخیره شده است.

| Silhouette | Responseld | شاخص ردیف | نوع      | خوشه |
|------------|------------|-----------|----------|------|
| ۰.۳۴۲۱     | ۴۶۹۷۲      | ۴۶۳۶۶     | medoid   | ۰    |
| ۰.۳۷۷۱     | ۴۴۲۵۵      | ۴۳۸۵۷     | exemplar | ۰    |
| -۰.۰۴۱۹    | ۳۶۳۰۷      | ۳۶۰۵۶     | boundary | ۰    |
| ۰.۰۸۴۳     | ۲۸۴۶۴      | ۲۸۲۶۱     | medoid   | ۱    |
| ۰.۲۱۸۴     | ۵۰۷۶۱      | ۴۹۶۵۷     | exemplar | ۱    |
| -۰.۱۷۱۱    | ۵۳۶۰۵      | ۵۲۳۰۹     | boundary | ۱    |

## Article VIII. ۶. قواعد توضیحی و SHAP


یک درخت تصمیم با عمق چهار روی برجسب consensus آموزش داده شد. fidelity روی holdout برابر ۹۸.۹٪ و fit نهایی روی کل داده ۹۸.۸٪ بود. قواعد کامل در artifact متنی ذخیره شدند.

SHAP اهمیت و جهت اثر مؤلفه‌ها را برای classifier توضیحی برآورد کرد. چون PCها ترکیب خطی ویژگی‌های اصلی‌اند، یک PC به تنهایی معادل مفهوم دامنه‌ای نیست؛ نتیجه SHAP باید همراه پروفایل‌های فناوری، loadings و نمونه‌های واقعی خوانده شود.

| مؤلفه | اهمیت مدل | میانگین  SHAP |
|-------|-----------|---------------|
| PC۱   | ۰.۹۵۳۲    | ۰.۴۷۲۹        |
| PC۳   | ۰.۰۴۵۵    | ۰.۰۲۳۸        |
| PC۳۳  | ۰.۰۰۱۲    | ۰.۰۰۱۹        |
| PC۲۲  | ۰.۰۰۰۰    | ۰.۰۰۰۱        |
| PC۲   | ۰.۰۰۰۰    | ۰.۰۰۰۰        |



| میانگین   SHAP | اهمیت مدل | مؤلفه |
|----------------|-----------|-------|
| ۰.۰۰۰۰         | ۰.۰۰۰۰    | PC۴   |
| ۰.۰۰۰۰         | ۰.۰۰۰۰    | PC۷   |
| ۰.۰۰۰۰         | ۰.۰۰۰۰    | PC۸   |
| ۰.۰۰۰۰         | ۰.۰۰۰۰    | PC۵   |
| ۰.۰۰۰۰         | ۰.۰۰۰۰    | PC۶   |
| ۰.۰۰۰۰         | ۰.۰۰۰۰    | PC۱۱  |
| ۰.۰۰۰۰         | ۰.۰۰۰۰    | PC۱۲  |
| ۰.۰۰۰۰         | ۰.۰۰۰۰    | PC۱۳  |
| ۰.۰۰۰۰         | ۰.۰۰۰۰    | PC۱۴  |
| ۰.۰۰۰۰         | ۰.۰۰۰۰    | PC۱۵  |



شکل ۳ — اهمیت SHAP مؤلفه‌های مؤثر بر انتساب

## Article IX. ۷. تحلیل پایین‌دستی جبران خدمت

Random Forest روی log جبران خدمت یک‌بار سراسری و سپس جداگانه در هر خوشه برازش شد. معیار MAE روی ردیف‌های آزمون مشترک مقایسه شد. مدل‌های شرطی در هیچ خوشه‌ای از مدل سراسری بهتر نبودند؛ بنابراین تقسیم‌بندی خوشه‌ای برای این پیامد دقت پیش‌بینی را بهتر نکرد.

| مدل                 | خوشه | ردیف آزمون | MAE log | MAE سراسری |
|---------------------|------|------------|---------|------------|
| global              | all  | ۵۸۴۷       | ۰.۷۰۷۹  | nan        |
| cluster_conditional | ۰    | ۴۴۲۹       | ۰.۷۰۹۷  | ۰.۶۹۷۶     |
| cluster_conditional | ۱    | ۱۴۱۸       | ۰.۷۴۵۹  | ۰.۷۴۰۰     |

نتیجه تحلیل جبران خدمت خوشه‌ها جبران خدمت را بهتر پیش‌بینی نکردند؛ بنابراین نباید از آن‌ها به‌عنوان شاخص ارزش اقتصادی یا سطح حرفه‌ای استفاده شود.

Isolation Forest با نرخ آلودگی یک درصد در هر خوشه جداگانه برازش و سپس یک درصد بالای امتیازها در کل cohort برای بازبینی انتخاب شد. ناهنجاری به معنای فاصله از الگوی رایج همان خوشه است، نه داده بد یا فرد نامطلوب. برازش درون‌خوشه‌ای مانع از آن می‌شود که اعضای یک پروفایل کوچک فقط به دلیل تفاوت با خوشه اکثریت ناهنجر محسوب شوند.

| امتیاز ناهنجاری | ResponseId | خوشه |
|-----------------|------------|------|
| ۰.۶۰۰۳          | ۵۷۷۳۸      | ۰    |
| ۰.۵۹۳۸          | ۲۴۷۴۲      | ۰    |
| ۰.۵۷۷۲          | ۵۶۲۵۹      | ۰    |
| ۰.۵۷۱۰          | ۴۹۹۳۷      | ۰    |
| ۰.۵۷۰۹          | ۶۲۲۳۰      | ۰    |
| ۰.۵۶۹۵          | ۵۸۰۸۶      | ۰    |
| ۰.۵۳۲۷          | ۳۱۰۸۳      | ۰    |
| ۰.۵۳۲۲          | ۴۴۶۰       | ۰    |
| ۰.۶۹۴۹          | ۶۳۵۲۱      | ۱    |
| ۰.۶۷۵۲          | ۵۳۴۷۰      | ۱    |
| ۰.۶۷۳۰          | ۲۶۶۷۸      | ۱    |
| ۰.۶۷۲۹          | ۲۲۶۲۸      | ۱    |
| ۰.۶۷۲۹          | ۴۸۵۶۳      | ۱    |
| ۰.۶۷۱۱          | ۴۷۹۵۰      | ۱    |
| ۰.۶۷۰۷          | ۳۸۶۶۲      | ۱    |
| ۰.۶۷۰۰          | ۲۵۶۸۴      | ۱    |

## Article XI. ۹. ممیزی composition و انصاف

ترکیب تحصیلات، دورکاری، کشور و پذیرش AI در هر خوشه محاسبه شد. هدف آشکارکردن stratification احتمالی است، نه اثبات رابطه علی. دسته‌های غالب نشان می‌دهند خوشه‌ها چگونه با metadata هم‌زمان تغییر می‌کنند و کجا استفاده عملی ممکن است متغیرهای جانشین نامطلوب ایجاد کند.


| ویژگی      | خوشه | دسته غالب                                    | سهم   |
|------------|------|----------------------------------------------|-------|
| AISelect   | ۱    | Yes                                          | ۶۷.۲٪ |
| AISelect   | ۰    | Yes                                          | ۵۷.۲٪ |
| EdLevel    | ۰    | Bachelor's degree (B.A., B.S., B.Eng., etc.) | ۴۰.۱٪ |
| EdLevel    | ۱    | Bachelor's degree (B.A., B.S., B.Eng., etc.) | ۳۸.۷٪ |
| RemoteWork | ۱    | Hybrid (some remote, some in-person)         | ۳۷.۲٪ |
| RemoteWork | ۰    | Hybrid (some remote, some in-person)         | ۳۴.۹٪ |
| Country    | ۰    | United States of America                     | ۱۸.۲٪ |
| Country    | ۱    | United States of America                     | ۱۸.۲٪ |

حد اخلاقی هیچ تصمیم فردی، استخدامی یا رتبه‌بندی نباید صرفاً بر اساس خوشه انجام شود. composition فقط برای audit و تفسیر گروهی گزارش می‌شود.

## Article XII. ۱۰. حساسیت و استحکام

انتساب نهایی با PCA-۵۰، PCA-۲۰، PCA-۱۰، نمایش کامل و سه scaler مقایسه شد. ARI نسبت به consensus میزان حفظ ساختار را می‌سنجد. دامنه وسیع ARI نشان می‌دهد بخش مهمی از پاسخ clustering به انتخاب هندسه پیش‌پردازش وابسته است.

| سناریو          | consensus به ARI نسبت |
|-----------------|-----------------------|
| PCA_۱۰          | ۰.۹۳۹                 |
| PCA_۲۰          | ۰.۸۷۴                 |
| PCA_۵۰          | ۰.۸۴۰                 |
| scaler_robust   | ۰.۶۶۴                 |
| scaler_minmax   | ۰.۳۱۴                 |
| scaler_standard | ۰.۲۶۲                 |



شکل ۴ — حساسیت برچسب به scaler، نمایش و تعداد مؤلفه

## Article XIII. ۱۱. Registry، نسخه‌بندی و drift

مدل centroid، assigner، reducer، scaler و مدل‌های مکمل با metadata، تاریخ برآزش، پارامترها، metric scoreboard و SHA-۲۵۶ ثبت شدند. baseline drift برای ده PC نخست با PSI و KS روی دو نیمه ثابت داده ساخته شد.  $PSI > 0.2$  یا  $KS > 0.1$  آستانه هشدار است؛ این قرارداد می‌تواند در داده سال‌های آینده با پنجره زمانی واقعی جایگزین شود.

| هشدار | p-value   | KS     | PSI    | ویژگی |
|-------|-----------|--------|--------|-------|
| False | ۱.۴۳۳e-۲۹ | ۰.۰۴۷۳ | ۰.۰۱۲۱ | PC۸   |
| False | ۷.۰۹۸e-۰۷ | ۰.۰۲۲۲ | ۰.۰۰۹۵ | PC۲   |
| False | ۲.۴۳۷e-۱۵ | ۰.۰۳۳۸ | ۰.۰۰۷۴ | PC۹   |
| False | ۲.۶۷۲e-۱۴ | ۰.۰۳۲۶ | ۰.۰۰۷۰ | PC۱   |
| False | ۴.۹۳۷e-۱۸ | ۰.۰۳۶۷ | ۰.۰۰۶۷ | PC۳   |
| False | ۲.۶۳۲e-۱۷ | ۰.۰۳۶۰ | ۰.۰۰۶۷ | PC۱۰  |
| False | ۱.۹۵۴e-۱۴ | ۰.۰۳۲۸ | ۰.۰۰۶۴ | PC۴   |
| False | ۶.۴۶۱e-۰۷ | ۰.۰۲۲۳ | ۰.۰۰۳۷ | PC۶   |
| False | ۷.۳۸۲e-۰۶ | ۰.۰۲۰۴ | ۰.۰۰۳۱ | PC۵   |
| False | ۰.۰۰۰۱۰۹۷ | ۰.۰۱۸۱ | ۰.۰۰۱۹ | PC۷   |


## Article XIV. ۱۲. مسیر دوم: NMF پربعد

برای مسیر پیشرفته دوم، NMF مستقیماً روی ۲۴۰ شاخص نامنفی فناوری اجرا شد. ویژگی breadth مقیاس شده کنار گذاشته شد تا فرض نامنفی بودن نقض نشود. انتخاب مؤلفه با silhouette کسینوسی در فضای فناوری، silhouette نهفته، کمترین سهم خوشه و reconstruction error انجام شد.

| انتخاب | ARI    | کمترین سهم | نهفته | Silhouette کسینوسی | مؤلفه |
|--------|--------|------------|-------|--------------------|-------|
| خیر    | -۰.۰۴۳ | ۳۰.۹٪      | ۰.۲۹۸ | ۰.۰۷۰              | ۲     |
| خیر    | -۰.۰۲۵ | ۱۷.۰٪      | ۰.۱۷۴ | ۰.۰۵۵              | ۳     |
| بله    | -۰.۰۰۸ | ۱۷.۲٪      | ۰.۳۳۸ | ۰.۰۹۸              | ۴     |
| خیر    | -۰.۰۰۶ | ۱۵.۴٪      | ۰.۳۰۱ | ۰.۰۹۰              | ۵     |

| مؤلفه | Silhouette<br>کسینوسی | نهفته | کمترین سهم | ARI   | انتخاب |
|-------|-----------------------|-------|------------|-------|--------|
| ۶     | ۰.۰۸۳                 | ۰.۲۶۹ | ۱۱.۱٪      | ۰.۰۰۳ | خیر    |

راحل ۴ مؤلفه با silhouette کسینوسی ۰.۰۹۸ انتخاب شد.  $ARI=0.008$  نسبت به consensus نشان می‌دهد NMF اکوسیستم فناوری را می‌یابد، در حالی که consensus عمدتاً breadth را خلاصه می‌کند.



شکل ۵ — مقایسه تعداد مؤلفه‌ها در مسیر NMF

## Article XV. ۱۳. استنباط آماری و پایداری split

### ۱۳.۱ permutation و Bootstrap


### Section ۱۵.۰۱

| کرن بالا | کرن پایین | برآورد | روش                |
|----------|-----------|--------|--------------------|
| ۰.۲۰۷۱   | ۰.۱۹۲۸    | ۰.۱۹۹۶ | consensus          |
| ۰.۲۰۳۶   | ۰.۱۸۹۳    | ۰.۱۹۷۱ | kmeans             |
| ۰.۲۲۴۰   | ۰.۲۰۹۳    | ۰.۲۱۷۸ | agglomerative_ward |

| کرن بالا | کرن پایین | برآورد | روش                  |
|----------|-----------|--------|----------------------|
| ۰.۰۲۸۳   | ۰.۰۱۷۳    | ۰.۰۲۲۴ | gmm_full_k3          |
| ۰.۱۳۳۸   | ۰.۱۲۳۰    | ۰.۱۲۸۳ | spectral_k3          |
| ۰.۰۱۳۲   | ۰.۰۰۵۳    | ۰.۰۰۹۲ | nmf_high_dimensional |

برای پنج معیار، ۲۰۰ بازنمونه‌گیری و برای مقایسه دو روش برتر ۵,۰۰۰ جایگشت انجام شد. اختلاف silhouette روش agglomerative\_ward نسبت به consensus برابر ۰.۰۱۸۲ با  $p=۰.۰۰۰۲$  بود.

| مقایسه            | روش اول            | روش دوم   | اختلاف | p      |
|-------------------|--------------------|-----------|--------|--------|
| best_vs_runner_up | agglomerative_ward | consensus | ۰.۰۱۸۲ | ۰.۰۰۰۲ |



شکل ۶ — فاصله اطمینان bootstrap برای silhouette


## Section ۱۵.۰۲

### ۱۳.۲. پایداری بین دو نیمه تجربه

داده در  $\text{ExperienceConsensus}=8$  تقسیم و هر نیمه مستقل خوشه‌بندی شد. پس از تطبیق prototype با Hungarian، میانگین Jaccard بیست فناوری شاخص ۰.۶۳۳ بود. این نتیجه پایداری متوسط را تأیید می‌کند و هم‌زمان تفاوت میان گروه‌های تجربه را حفظ می‌کند.



| Jaccard | ردیف دوم | ردیف اول | خوشه دوم | خوشه اول |
|---------|----------|----------|----------|----------|
| ۰.۶۰۰   | ۵۵۱۶     | ۱۳۱۸۷    | ۱        | ۰        |
| ۰.۶۶۷   | ۲۲۶۷۱    | ۱۸۶۴۹    | ۰        | ۱        |



شکل ۷ — تطبیق prototype میان دو نیمه تجربه

## Article XVI. ۱۴. داشبورد و خروجی عملیاتی

داشبورد Streamlit پنج صفحه دارد: Overview، Cluster Explorer، Evaluation، Live Assignment و ۳D Explorer. صفحه انتساب رکورد یا CSV دارای PC۱ تا PC۵۰ را می‌پذیرد و برچسب و فاصله تا هر centroid را برمی‌گرداند. UMAP سه‌بعدی تعاملی روی ۱۰,۰۰۰ رکورد در داشبورد و فایل HTML مستقل ذخیره شده است. هیچ فاصله‌ای در UMAP برای برازش خوشه نهایی استفاده نشده و نمایش صرفاً اکتشافی است.

## Article XVII. ۱۵. محدودیت‌ها و نتیجه

- Silhouette متوسط و boundaryهای منفی نشان می‌دهند دو پروفایل overlap دارند.
- حساسیت به scaler و کاهش بعد، ادعای ذاتی بودن خوشه‌ها را تضعیف می‌کند.
- داده خوداظهاری، داوطلبانه و تک‌ساله است؛ تعمیم زمانی یا جمعیتی قطعی نیست.

- مدل پایین‌دستی جبران خدمت بهبود نداشت و کاربرد پیش‌بینی اقتصادی تأیید نشد.
- SHAP روی PC‌ها غیرمستقیم است و باید همراه فناوری‌ها و loadings خوانده شود.

Consensus یک تقسیم قابل توضیح و بازتولیدپذیر میان پشته متمرکزتر و breadth گسترده‌تر فراهم کرد، اما کاربرد آن در اکتشاف، خلاصه‌سازی و تولید فرضیه است. مسیر NMF، استنباط bootstrap/permutation، پایداری split و UMAP سه‌بعدی تصویر مکملی از ساختار ارائه می‌کنند و مانع تقلیل کل داده به یک پاسخ ساده می‌شوند.

## Article XVIII منابع

منبع داده: ۲۰۲۴ Stack Overflow Developer Survey. منابع روش شامل NMF، Consensus Clustering، UMAP، Scikit-learn و SHAP هستند. تمام محاسبات و اعداد از کد و خروجی‌های همین پروژه تولید شده‌اند.

```
.\env\Scripts\python.exe -m scripts.run_phase3 --config config.yaml
```