



دانشگاه صنعتی خواجه نصیرالدین طوسی

دانشکده مهندسی کامپیوتر

انتخاب موضوع و مجموعه داده پروژه

انتخاب موضوع و مجموعه داده

مرصاد احمدی — علی حسن زاده

۴۰۳۰۴۴۶۴ — ۴۰۳۰۱۲۷۴

استاد: دکتر پیشگو

تیر ۱۴۰۵ / ۲۰۲۶ July

فهرست مطالب	۲
خلاصه انتخاب	۳
۱. معرفی مجموعه داده	۳
۱.۱. تناسب داده با خوشه بندی	۳
۱.۲. محدودیت های منبع	۴
۲. متغیرهای منتخب	۴
۳. فرضیه های ساختاری و سبد الگوریتم	۴
۴. برنامه آماده سازی و نمایش	۵
۵. برنامه ارزیابی	۵
۶. معیار موفقیت و خروجی ها	۶
منبع	۶

Article II. خلاصه انتخاب

موضوع پروژه، کشف و تفسیر پروفایل‌های توسعه‌دهندگان با استفاده از خوشه‌بندی بدون نظارت است. داده اصلی، پیمایش عمومی توسعه‌دهندگان Stack Overflow در سال ۲۰۲۴ است که ۶۵'۴۳۷ پاسخ و ۱۱۴ ستون دارد. ترکیب تجربه، وضعیت کار، اندازه سازمان، کشور و فناوری‌های استفاده‌شده امکان مطالعه ساختارهای چندمتغیره را فراهم می‌کند.

پرسش مرکزی چه پروفایل‌هایی از الگوهای مشترک پشته فناوری، تجربه حرفه‌ای و بستر کاری توسعه‌دهندگان پدیدار می‌شوند و این پروفایل‌ها چه ارتباطی با نقش، تحصیلات و پذیرش ابزارهای هوش مصنوعی دارند؟

مؤلفه	انتخاب
مجموعه داده	Stack Overflow Developer Survey ۲۰۲۴
تعداد پاسخ	۶۵'۴۳۷
تعداد ستون خام	۱۱۴
نوع مسئله	خوشه‌بندی و تفسیر بدون نظارت
واحد تحلیل	پاسخ‌دهنده پیمایش
خروجی مورد انتظار	پروفایل، پایداری، قواعد توضیحی و dashboard

Article III. ۱. معرفی مجموعه داده

فایل survey_results_public.csv پاسخ‌های پیمایش و survey_results_schema.csv متن و نوع پرسش‌ها را نگه می‌دارد. داده عمومی، مستند و دارای حجم کافی برای مقایسه روش‌های مقیاس‌پذیر است. هر ردیف یک پاسخ‌دهنده و هر ستون بخشی از تجربه، نقش، شرایط کار یا فناوری‌های او را توصیف می‌کند.

Section ۳.۰۱. ۱.۱. تناسب داده با خوشه‌بندی

- ترکیب هم‌زمان متغیرهای عددی، رده‌ای و چندبرچسبی، مسئله‌ای پربعد ایجاد می‌کند.
- هفت حوزه فناوری امکان مطالعه ترکیب پشته و breadth را فراهم می‌کنند.
- تعداد بالای پاسخ‌ها برای سنجش پایداری seed و bootstrap مناسب است.
- وجود schema رسمی باعث می‌شود تعریف ستون‌ها و مراحل پاک‌سازی قابل بررسی و تکرار باشند.

Section ۳.۰۲. ۱.۲. محدودیت‌های منبع

پیمایش خوداظهاری و داوطلبانه است و نماینده کامل همه توسعه‌دهندگان جهان نیست. گمشدگی، تفاوت مشارکت کشورها و تفسیر متفاوت پرسش‌ها باید در تحلیل لحاظ شود. نتیجه خوشه‌بندی توصیفی است و برای رتبه‌بندی یا تصمیم‌گیری فردی طراحی نشده است.

Article IV. ۲. متغیرهای منتخب

متغیرهای فضای خوشه‌بندی از سه گروه اصلی انتخاب شدند: تجربه برنامه‌نویسی و کار، بستر شغلی، و پشته فناوری. متغیرهای نقش، تحصیلات، پذیرش AI و جبران خدمت از فضای خوشه‌بندی کنار گذاشته شدند تا فقط برای تفسیر یا تحلیل پایین‌دستی استفاده شوند.

نقش در تحلیل	متغیرها	دلیل
شناسه و کنترل کیفیت	ResponseId, MainBranch, Check	ردیابی و کنترل اعتبار پاسخ
تجربه	YearsCode, YearsCodePro, WorkExp	سطح و پراکندگی تجربه
بستر کاری	OrgSize, Employment, RemoteWork, Country	شرایط سازمانی و جغرافیایی
فناوری	HaveWorkedWith هفت ستون	ترکیب پشته و breadth
تفسیر	DevType, EdLevel, AISelect	متغیر کمکی برای تفسیر؛ نه برجسته مرجع
پایین‌دستی	ConvertedCompYearly	ارزیابی ارزش افزوده segmentation

Article V. ۳. فرضیه‌های ساختاری و سبد الگوریتم

پیش از مشاهده نتیجه، یک شکل هندسی واحد برای داده فرض نمی‌شود. خانواده‌های مختلف برای پوشش ساختارهای کروی، سلسله‌مراتبی، چگالی‌متغیر، احتمالاتی و غیره انتخاب شدند. مقایسه روی نمونه و نمایش مشترک انجام می‌شود تا اختلاف امتیاز ناشی از تغییر داده نباشد.

ساختار مورد انتظار	روش	نقش در مطالعه
کروی و centroidمحور	K-Means / MiniBatch	مرجع مقیاس‌پذیر روی کل داده
سلسله‌مراتبی	Agglomerative	مقایسه linkage و برش
چگالی‌متغیر و نويز	DBSCAN / HDBSCAN / OPTICS	آزمون شکل نامنظم و نويز

نقش در مطالعه	روش	ساختار مورد انتظار
عضویت نرم و AIC/BIC	Gaussian Mixture	مدل احتمالاتی
افزایش تنوع نامزدهای ensemble	Spectral	ساختار غیرکوژ
کاهش وابستگی به یک الگوریتم	Consensus	تجمیع چند مدل

Article VI. ۴. برنامه آماده‌سازی و نمایش

- تبدیل عبارت‌های تجربه به مقدار عددی و حفظ indicator گمشدگی.
- ادغام کشورهای کم‌فراوانی و کدگذاری متغیرهای رده‌ای.
- تفکیک ستون‌های فناوری با semicolon و ساخت نمایش multi-hot.
- مقایسه RobustScaler، StandardScaler و MinMaxScaler و انتخاب مسیر اصلی.
- ساخت نمایش کامل ۳۲۸ ویژگی، نمایش فناوری ۲۴۱ ویژگی و PCA با ۵۰ مؤلفه.
- استفاده از UMAP فقط برای اکتشاف بصری، نه برازش خوشه نهایی.

Article VII. ۵. برنامه ارزیابی

وجود گرایش خوشه‌ای پیش از انتخاب مدل با Hopkins و VAT بررسی می‌شود. تعداد خوشه فقط از یک معیار به دست نمی‌آید؛ Elbow، Silhouette، Gap Statistic، Davies–Bouldin، Calinski–Harabasz، Dunn و BIC در کنار پایداری و تفسیر استفاده می‌شوند.

معیار یا روش	بعد ارزیابی
VAT و Hopkins	گرایش خوشه‌ای
Dunn و Silhouette، DB، CH	جدایش و فشردگی
BIC و Elbow/Kneedle، Gap	انتخاب k
تغییر seed و bootstrap	پایداری
ARI زوجی و co-association	توافق مدل‌ها
پروفایل، فناوری شاخص، exemplar، درخت و SHAP	تفسیر
رگرسیون جبران خدمت و ناهنجاری خوشه‌محور	ارزش پایین‌دستی

ارزیابی پروژه فقط به یک آستانه Silhouette محدود نمی‌شود. نتیجه از نظر ساختار، پایداری، تفسیر، حساسیت و محدودیت‌ها بررسی خواهد شد. اگر معیارها پاسخ‌های متفاوتی بدهند، این اختلاف نیز در گزارش توضیح داده می‌شود.

- pipeline قابل اجرای مجدد از فایل خام تا گزارش نهایی.
- مقایسه مستند پنج خانواده الگوریتم و ثبت تنظیمات ناموفق.
- گزارش پایداری، حساسیت و نقاط مرزی در کنار معیارهای داخلی.
- گزارش‌های فارسی notebook، DOCX/PDF، dashboard و تعاملی.
- تفسیر مسئولانه و پرهیز از استفاده فردی یا علی از شناسه خوشه.